



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 澳门大学、北京师范大学

参赛队号 26999030003

队员姓名	1. 廖启斌
	2. 李俊贤
	3. 黄孙宏

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

大语言模型的能力同时受训练数据质量、领域配比、参数规模、数据量、上下文长度与算法效率影响，而附件 A、B、C 的观测单位与证据强度并不一致。全文先对全部附件做逐文件审计、字段校验与异常隔离，再建立“质量评价—配比与 Loss 响应—质量扩展标度律—算力约束配置—能力前沿预测”的模型链。每类结果都标注证据等级，直接记录、同源留出、半合成校准、估算参考与情景预测分别报告，文件级接口自检与跨问联合模型的端到端验收状态也分别说明。

问题一：对 A1–A16 按记录来源和结构差异进行审计，将 A1–A3 的 22 项指标归入启发式质量、DSIR 相关性和判别器质量三个语义组，采用“组间等权、组内熵权与 Spearman 冗余修正”的分层综合评分，并通过 500 次域内重抽样给出七个领域的不确定区间；有效去重并集共 261,056 条记录。配比建模以 17 维领域比例预测 13 维验证 Loss，在相同切分下比较参考域参数化 Ridge 与逐目标 LightGBM。冻结 LightGBM 在 1M 留出集和整簇留出上的宏 NRMSE 分别为 **0.1309** 和 **0.2391**，且在 60M、1B 留出上的平均 Spearman 分别为 0.9836、0.9487。删除四项方向暂定指标后，Top 1% 重合率降至 0.1536；A16 的可靠映射覆盖六域，加入质量代理未带来稳定的独立预测增益。

问题二：在 B1 上拟合经典 $N-D$ 幂律，再引入附件自身的质量变量 Q_B ，构造质量扩展的条件 Loss 函数，并以 B7-new 检验新质量水平的外推。B6 组交叉验证中，无质量模型与含质量模型的 RMSE 分别为 **0.12876** 和 **0.07609**；B7-new 留出上分别为 **0.05896** 和 **0.04909**，说明在同一半合成机制附近加入质量项能降低预测误差。M2 配比响应候选文件的哈希、字段与基准点自检通过，但正式 $Q_1 \rightarrow Q_2$ 质量/配比接口及完整联合模型尚末端到端验收； $Q_A \rightarrow Q_B$ 映射与配比迁移按情景处理。B8 的 150/150 个固定组呈现与 B6/B7 主设定相反的质量–Loss 方向，单独列为压力测试。

问题三：将问题二 MQ 主模型写入算力约束，在标度律支持盒内优化参数量 N 、训练数据量 D 与质量水平 Q ；领域配比依据问题一响应接口单独开展离散候选情景比较，不再视为已识别的连续联合最优。预算同时计入基础训练、长上下文注意力及质量处理开销。三档注意力成本系数、五档 C7 支持上下文、三类质量成本和三档预算组成 135 个情景，其中 **123 个可行**；默认 $\eta = 2 \times 10^{-4}$ 的 45 个主情景中 **42 个可行**。60/60 次组重抽样传播与 9/9 个局部数值/KKT 检验均通过。最优约束状态随预算和上下文切换，高预算方案触及数据、质量或参数支持上界。

问题四：结合固定版本、评测记录与任务协议完成开放权重主样本筛选和 C8 审计，以六项任务宏平均描述综合能力。通过三类有界候选的留组验证与稳健平均回退，给出 pretrained 和 chat/finetuned 两条轨道的 12/24 个月条件情景；点值分别为 37.3107/41.2719 分和 38.5715/42.5756 分，27 种规格包络显示远期结果对设定敏感。规模/时间分解仅作条件归因，Loss–Benchmark 桥接未通过跨家族验证，故不据此宣称行业因果贡献或已验证的长期预测。

整体上，在统一框架内条件化比较规模、数据、质量、配比与上下文成本：建立可追溯的跨问候选输入与文件级自检，以语义组平衡抑制相关指标的重复计权，并用留

出、整簇、方向冲突、KKT 与结构权重开展多层检验。质量映射与配比迁移尚未由联合实验识别，因此相关资源比较均为明确假设下的条件情景。

关键词： 数据质量评价；领域配比；标度律；算力约束优化；能力前沿；证据分级

目录

一、 问题重述	5
1.1 算力预算下的训练资源权衡	5
1.2 四项建模任务	5
二、 问题分析	6
2.1 问题一：从质量信号到配比响应	6
2.2 问题二：质量扩展标度律的构造与检验	6
2.3 问题三：预算约束下的资源配置	6
2.4 问题四：能力增长的来源分解	7
三、 模型假设	8
四、 符号说明	9
五、 技术路线图	10
六、 问题一模型的建立与求解	11
6.1 数据审计与证据分级	11
6.2 从原始信号到综合质量分	12
6.2.1 指标语义与尺度统一	12
6.2.2 语义分组下的权重分配	13
6.3 评分规则的敏感性检验	13
6.3.1 指标方向与权重扰动	13
6.3.2 质量冲突的识别与比较	16
6.4 配比对验证 Loss 的预测	18
6.4.1 数据划分与预测器选择	18
6.4.2 单域扰动与组合响应	19
6.5 质量映射的覆盖范围	21
6.6 审计样本的纳入范围	22
6.7 指标方向的设定及其解释边界	23
6.8 质量冲突下的样本保留	24
6.9 质量代理在配比预测中的检验	24
6.9.1 质量评分与配比响应的数值核验	25
6.10 问题一主要结论	25
七、 问题二模型的建立与求解	27
7.1 经典标度律的基准拟合	27
7.2 质量项的通道设定与检验	28
7.3 配比响应接口的支持范围	29
7.4 来源差异下的广义标度律	31
7.5 边际效应与弹性网格	31
7.6 质量对规模的替代条件	31
7.7 问题二主要结论	32
7.7.1 广义标度律边际效应与等损失替代推导	32

八、 问题三模型的建立与求解	34
8.1 预算约束下的联合配置模型	34
8.2 预算档位下的配置结果	34
8.2.1 活动约束与主导成本区间	35
8.3 上下文长度下的不确定性传播	36
8.3.1 成本约束与 KKT 最优性核验	38
九、 问题四模型的建立与求解	39
9.1 固定版本主样本的筛选口径	39
9.2 有界能力动态模型的留组验证	39
9.3 增长来源的条件归因	40
9.4 分轨能力前沿情景预测	41
9.4.1 有界分数映射与预测情景范围	42
9.5 Loss-Benchmark 桥接检验	43
十、 模型评价与总体结论	44
10.1 分层验证设计	44
10.2 模型的稳健性验证	44
10.3 跨问题的误差传递	44
10.4 资源配置结果的应用条件	45
10.5 模型局限性	45
10.6 总体结论	45
AI 使用声明	48
附件 A 数据附件使用表	49
附件 B Python 核心代码	50
B.1 问题一：质量评分与配比验证	50
B.2 问题二：质量扩展标度律	58
B.3 问题三：算力预算情景求解	61
B.4 问题四：版本动态与分轨情景	65

一、 问题重述

1.1 算力预算下的训练资源权衡

大语言模型的训练效果受参数规模、训练数据量和数据组成共同影响。在算力预算有限的条件下，增加参数、延长训练或提高语料质量并不能无限同时进行。数据集即使拥有相近的文本量，也可能因教育价值、语言流畅性、文档结构及领域覆盖的差异而产生不同的训练效果。因此，资源配置问题不仅要回答“使用多少数据”，还要回答“使用什么数据，以及各类数据占多少”。

赛题以验证集交叉熵损失（以下简称 Loss）描述模型对文本的预测误差，以多个下游评测指标描述模型能力。Loss 越低通常表示预测越准确，但它与具体下游能力并不等价。题目将参数量 N 、训练数据量 D 、数据质量 Q 和领域配比向量 p 作为主要因素，并要求在后续问题中考虑算力预算和上下文长度的影响。不同附件同时包含直接观测、半合成和外推估算数据，因而数据来源与证据等级必须贯穿建模和解释过程。

题目将任务分为质量与配比、广义标度律、算力约束配置和能力演进四部分，其具体要求如下。

1.2 四项建模任务

题目要求依次完成以下任务。

1. **问题一：质量与配比。**对 A1–A3 中 22 项质量信号确定转换和评价方向，构造可复核的样本级及领域级质量分 Q ；比较不同指标给出不一致评价的程度及来源。再利用 A4–A15 中的 17 维配比 p 和 13 维验证 Loss 建立预测关系，区分训练、留出检验和既有外推估算；若关联 Q 与 p ，须说明 A16 映射的覆盖范围。
2. **问题二：广义标度律。**在问题一输出的 Q 与 p 基础上，结合附件 B 研究参数规模、数据规模、质量和配比与 Loss 的关系，分析各因素的边际效用。半合成补充数据和估算数据须单独标识。
3. **问题三：算力约束下的配置。**以前两问的经验关系为输入，在不同算力预算下选择参数量、数据量、数据质量和领域配比；上下文长度按题意作为外生条件，并检验给定参数盒与成本假设下的条件最优策略是否随预算发生结构性转移。
4. **问题四：能力演进。**依据附件 C 分析规模扩张与非规模技术进步的相对贡献，建立 Loss 与多维评测得分之间可比的桥接关系，并讨论未来能力前沿及其不确定性。

二、 问题分析

四个问题围绕“数据如何评价、规律如何刻画、预算如何分配、能力如何演进”逐层展开。问题一从数据质量与领域配比出发，形成质量评分 Q 、配比向量 $\mathbf{p}$ 与 Loss 的经验关系；问题二将这些数据因素纳入标度律；问题三把所得关系转化为算力约束下的资源配置模型；问题四再利用历史能力数据区分规模扩张与非规模技术进步，并预测能力前沿。因此，各问既要独立完成题目要求，也要保证变量定义、证据口径和跨问接口一致。

2.1 问题一：从质量信号到配比响应

问题一包含质量评价、质量冲突消解和领域配比建模三个相互关联的任务。首先，A1–A3 给出的 22 项质量指标在取值形式和优劣方向上并不一致，需要先识别标量型与列表型指标的含义，再把各指标统一转换到“数值越大、质量越高”的可比尺度。在此基础上构造样本级质量分 Q ，并明确从样本向语料或领域聚合的方法。题目要求同时使用抽样集与两个扩展集，因此还需比较 A1 与 A2、A3 的域级结果，判断评分规则在不同来源上的适用性。

其次，同一文本在教育价值、流畅性、广告含量等指标上可能呈现不同评价。这种差异可以转化为可计算的冲突指标，用于分析指标相关性、评价维度和文本多重属性的作用，并构建保留多维信息的综合评价规则。评分规则先在抽样集上解释，再在扩展集上检验结论的一致性；同时结合原始文本或可追溯样本核验指标语义。

最后，A4–A15 要求研究 17 个领域的数据配比与 13 个验证域 Loss 之间的关系。由于配比各分量非负且总和为 1，模型必须显式处理单纯形约束，并分别分析单领域变化及领域组合的影响。A6–A11 用于检验模型在不同设置下的预测与排序能力，A12–A15 用于讨论外推结论的稳健性。质量数据与配比实验采用不同的领域体系，若将 Q 引入配比模型，还需依据 A16 建立可解释的跨体系映射，并说明映射覆盖范围和由此产生的不确定性。

2.2 问题二：质量扩展标度律的构造与检验

问题二在经典标度律的参数规模 N 和数据规模 D 基础上，引入数据质量 Q 与领域配比 $\mathbf{p}$ ，建立广义 Loss 关系。模型保留经典关系的基本结构，并明确质量项和配比项的作用形式及其退化条件。针对赛题附件 A、B 各自独立的实验设计，通过可检验假设和统一的 Loss 口径衔接两类证据，并分别保留其观测单位。

该问还要求分析各因素的边际效用与弹性。因而参数估计之后，需要分别求出 Loss 对 N 、 D 、 Q 和 $\mathbf{p}$ 的局部响应，比较增加参数、增加数据和提升质量在不同工作点上的收益。对于领域数据之间的替代或互补关系，应考察配比联合变化产生的响应是否能够由各自效应相加解释。进一步地，在保持预测 Loss 不变的条件下，可通过全微分或等值曲线推导质量提升与参数扩张相互替代的条件。B6–B8 属于真实数据校准的半合成补充集，B9、B10 涉及大规模外推，因此其作用应与直接实验观测分开表述，并通过插值、跨族或文献数据完成检验。

2.3 问题三：预算约束下的资源配置

问题三把前两问得到的 Loss 关系转化为算力约束下的联合优化问题。决策对象包括参数量 N 、训练数据量 D 、数据质量 Q 和领域配比 $\mathbf{p}$ ；上下文长度 ℓ 由模型架构和任务需求外生给定，只作为情景变量参与比较。总算力由基础训练开销、数据质量提升

开销和长文本注意力开销构成，因此优化目标是在预算不超过 C 的条件下，使广义标度律预测的 Loss 尽可能低。

求解时纳入三类约束。第一， N 、 D 和 Q 在前两问数据支持范围内取值，并由此确定优化参数盒。第二， p 位于 17 维单纯形，可作为联立决策变量或采用前两问确定的候选配比，并报告相应选择依据。第三，对题目给出的指数型、幂函数型和对数渐进型质量成本分别求解，比较不同成本设定下的最优配置。

题目还要求判断预算增加时资源配置是否发生结构性转移。以活跃约束、主导成本项和最优变量边界状态作为可检验定义，以此识别低、中、高预算下的策略分区。上下文长度依据 C7 设置可行情景，并解析计算注意力开销与基础训练开销相当的临界长度 ℓ_{crit} ，进而比较不同 ℓ 对可行域和最优配置的影响。

2.4 问题四：能力增长的来源分解

问题四要求解释大语言模型能力增长的来源，并预测算力增长放缓情景下的未来能力前沿。第一步是定义可比较的综合能力指标，同时统一模型筛选、时间轴和版本口径。开源模型应明确是否要求开放权重以及许可证是否支持研究复现；预训练基础模型与对话或微调模型需要分组处理；模型时间则应统一采用提交、发布或版本日期中的一种口径。

在口径统一后，需要利用附件 C 中的模型规模、训练数据量、算力和时间信息，把能力变化分解为规模扩张贡献与非规模技术进步贡献。规模贡献描述由参数、数据和算力增长解释的部分，剩余的时间变化可作为架构、对齐和数据工程等非规模因素的综合代理。两部分贡献的定义必须建立在同一基准上，并通过不同模型设定或样本范围检验分解结果是否稳定。

前三问以交叉熵 Loss 为核心输出，而本问主要使用多维 Benchmark 得分，因此还需利用 C5 或 C6 建立 Loss-Benchmark 映射，并按可比性等级区分样本。映射误差应继续传递到能力分解和预测区间中。与此同时，题目要求对 C8 至少开展一项逐任务聚合分析，以避免综合得分掩盖不同任务的异质性。最终在算力增长放缓的情景下预测未来 12 个月或 24 个月的开源模型能力前沿，并同时报告点预测、区间范围及其对增长假设、桥接误差和样本口径的敏感性。

四问的输入、主要变量与输出见图 1。问题一输出 Q 与 p 的度量规则，问题二输出广义 Loss 关系，问题三输出预算条件下的资源配置，问题四完成 Loss 与实际能力指标的桥接。跨问传递依据变量口径和数据来源逐项匹配；对于需要假设衔接的部分，明确列出假设并开展不确定性分析。

三、 模型假设

本研究在明确的数据口径、函数形式与适用范围内建立四问模型。各项假设对应实际数据结构和计算条件，并在相应章节通过留出检验、敏感性分析或数值核验考察其影响。

1. **质量信号口径。**A1–A3 中同名指标按同一语义进行转换，并使用共同参考尺度；合法记录按既定转换规则形成“越高越好”的标准化值。22 项指标依语义划分为三组，组间各占总权重的 $1/3$ ，组内权重由熵差异和 Spearman 冗余修正确定。指标方向与分组规则作为评分定义，并以方向、权重敏感性分析考察其影响。
2. **配比数据与响应。**A4–A15 的配方表和 Loss 表以 index 对齐，17 维配比满足非负且分量和为 1。1M 配方用于模型拟合和选择，A6–A11 按同尺度及跨尺度留出方案评价预测表现；模型输出描述给定配比支持范围及扣减路径下的条件响应。
3. **质量与配比关联。**质量文本与配方实验按各自观测单位分析，A16 的映射按 direct、near-direct 与 inferred 类型及覆盖范围使用。配比加权质量代理用于表达已覆盖质量域的组合特征，并同步报告映射覆盖率。
4. **跨附件质量尺度。**问题一的 Q_A 与问题二附件中的 Q_B 分别保留原有定义和尺度。B6/B7 的质量响应解释为其半合成校准体系下的函数关系； $Q_A \rightarrow Q_B$ 映射和 M2 配比响应均以候选接口或情景参数表示，主预算分析取 $\lambda_p = 0$ ，其他取值用于敏感性比较。
5. **标度关系形式。**经典幂律及质量扩展形式作为经验参数化，用于拟合指定数据层和支持范围内的 Loss 响应。各来源参数按相应校准数据解释；外推结果通过来源分层、留出检验和支持域说明限定适用范围。
6. **算力成本与决策范围。**问题三采用 $6ND$ 近似基础训练开销，并加入 $\eta ND\ell$ 长上下文成本及 $D[g(Q) - g(Q_0)]_+$ 质量处理成本。上下文长度 ℓ 和系数 η 按情景给定；主预算模型将直接配比 FLOPs 成本设为零，配比影响另按候选响应分析。 N, D, Q 的优化限制在正文所列校准盒内。
7. **能力度量与时间口径。**问题四以六项任务的等权宏平均作为能力分数，并以固定版本日期构造时间变量；任务内季度第 90 百分位数用于描述筛选样本中的高分位前沿，其解释范围对应当前样本与评测口径。
8. **分轨预测。**Pretrained 与 chat/finetuned 两类模型分别拟合；能力映射采用有界函数并以 100 分为上限。12/24 个月结果是在给定锚点、增长组合、规格模板和情景参数下的条件预测，短期滚动检验范围按实际回测跨度报告。

四、 符号说明

符号	含义	单位或范围
i, j, k, g, v	样本、指标、供给域/目标域、指标组与验证目标的索引	按所在问题取值
$W, V, \mathcal{E}, T, O$	Q4 开放权重、固定版本、评测证据、任务协议筛选集合及其交集	候选模型集合
x_{ij}, s_{ij}, z_{ij}	样本 i 的原始质量信号、语义转换值与标准化质量信号	$z_{ij} \in [0, 1]$
G_g, ρ_{jk}, d_j	指标组、指标相关系数与熵差异	无量纲
$R_{j g}, u_{j g}, w_j$	组内冗余、组内权重与全局权重	权重非负且和为 1
Q_i^H, Q_d^H, C_i	样本综合质量分、领域平均质量分与样本质量分歧指数	$Q \in [0, 100]$; $C_i \in [0, 1]$
Q_A, Q_B, Q, Q_0	Q1 综合质量评分、Q2 质量变量、Q3 优化质量变量及其成本基准	$Q_A \in [0, 100]$; Q3 中 $Q, Q_0 \in [0.5, 1]$; Q_B 无量纲
$\mathbf{p}, \mathbf{p}_0, h_{p,v}(\mathbf{p}), h_p(\mathbf{p})$	领域配比、参考配比、验证目标 v 的相对对数 Loss 响应及其聚合值	$\mathbf{p} \in \Delta^{16}$ (17 个分量, 和为 1); h_p 无量纲
N, D, L, L_0, L_Q, L_s	参数量、训练数据量、观测 Loss、经典标度 Loss、质量扩展 Loss 与来源 s 的广义 Loss	N, D 在标度律中以十亿计; L 为交叉熵
$E, A, B, \tilde{E}, \tilde{A}, \tilde{B}, c_s$	基线、尺度系数及来源偏移参数; 带波浪号者为质量扩展模型参数	由所用 Loss 参数化确定
B_{eff}, γ	Q3 等价参数化中的有效数据系数与质量系数	由 Q2 参数化确定
$\alpha, \beta, \rho_N, \rho_D, E_1$	参数/数据幂律指数、质量通道系数与质量线性项系数	无量纲或由函数定义确定
$\lambda_p, \theta_{Qp}, Q_{\text{ref}}$	配比响应迁移情景系数、质量—配比交互系数与交互参考质量	无量纲
U_N, U_D	质量扩展标度律中的参数通道项与数据/配比通道项	Loss 尺度
C, C_{use}	总算力预算与给定配置的算力成本	FLOPs
$\ell, \eta, K(\ell)$	上下文长度、注意力成本系数及基础/注意力合成系数	ℓ 为 token; $K(\ell) = 6 + \eta\ell$
$g(Q), \Psi(Q)$	质量成本函数及相对基准质量的额外处理成本	成本/token;
C_N, C_D, C_Q	算力成本对 N, D, Q 的偏导	$\Psi(Q) = [g(Q) - g(Q_0)]_+$ 依决策变量单位计
L_N, L_D, L_Q, μ	Loss 对 N, D, Q 的偏导与预算约束的拉格朗日乘子	依决策变量单位计; $\mu \geq 0$
$n, d, c, \psi(Q)$	Q3 无量纲成本推导中的十亿参数数值、十亿 token 数值、 10^{18} FLOPs 预算数值与缩放质量成本	无量纲; Q1 的 n 表示有效样本量
$S_i(t), S_0, \eta_i(t), \sigma(\cdot), h$	模型 i 的能力分数、预测锚点分数、潜在动态预测量、Logistic sigmoid 函数与预测跨度	分; $S_i, S_0 \in [0, 100]$; h 为月
b_N, b_T, g_N, g_S, r, t	规模系数、时间系数、参数年对数增长率、能力初始年对数增长率、Logistic 参数与时间	年 ⁻¹ ; t 为年

五、 技术路线图

全文按数据层、方法层与验证层三层组织。数据层汇总附件 A、B、C 的观测单位差异，先做逐文件校验、精确去重与异常隔离，再按证据强度分级，避免把半合成校准与外推估算当作直接观测。方法层按问题顺序推进：问题一给出质量评价与配比响应，问题二把质量变量写入条件标度律，问题三在算力预算下求资源配置，问题四以固定版本与多任务评测刻画能力前沿。验证层逐问给出检验手段，包括留出与整簇验证、方向冲突反例、重抽样与 KKT 核验、留组验证与稳健平均回退；跨问传递受接口自检、成本假设与桥接条件约束。

为避免把不同性质的数字混为一谈，全文统一使用五级证据口径。直接记录指附件中的原始观测或可复核的字段，如 A1–A3 的质量信号与 C8 的评测 JSON；同源留出指在同一生成机制内被隔离、未参与拟合的观测，如问题一的 1M 留出与问题二的 B7-new；半合成校准指以真实数据为基准生成、用于补充机制的网格，如 B6–B8；估算参考指来自既有文献或估算表、只作一致性比较的数值，如 A12–A15 的 10B/70B Loss；情景预测指在给定假设下计算、尚无可比前瞻观测的结果，如问题四的 12/24 个月前沿。证据级别越低，结论的适用范围越窄，报告时必须附带相应的敏感性或反向证据。

三层之间的传递也有明确边界。数据层到方法层的输入是各附件原生的变量与单位，不预先做跨附件换算；方法层内部的跨问传递以显式接口或情景参数表示，凡不能由现有数据识别的量（如 $Q_A \rightarrow Q_B$ 映射、配比迁移 λ_p 、质量成本函数）都不作点估计；验证层的检验对象逐问不同，通过某一层的检验不自动支持下一层，例如问题三的 KKT 核验只保证给定成本式下的数值最优性，问题四的短期回测也不构成 24 个月区间的覆盖率证据。




图 1 三层技术路线：数据层、方法层、验证层

六、 问题一模型的建立与求解

从多指标综合评价看，质量评分需要先统一指标方向与尺度，再确定指标的相对权重。熵权法依据指标在样本间的离散程度分配信息权重，Spearman 相关修正用于降低相关指标重复计权；这两步刻画的是评分信号的区分度与冗余结构，而非指标对训练收益的因果作用^[1]。配方数据则是单纯形上的组成向量，预测模型必须在配比和为 1 的约束下解释 Loss 响应。岭回归以 L_2 惩罚稳定相关预测变量下的线性估计，LightGBM 通过树模型表达非线性与局部交互，分别作为平滑基准与灵活预测器^[2-3]。

附件 A1–A3 提供质量信号，A4–A15 提供领域配比与验证 Loss，A16 提供跨领域映射。质量记录与配方实验没有逐记录对应关系。为此，先审计并统一质量指标，再评价综合质量及指标分歧；配比响应单独建模，最后仅在可靠映射范围内讨论两者的关联。

综合质量分采用“语义定向—尺度统一—组内赋权—组间平衡”的构造思路：熵差异刻画指标对样本的区分能力，Spearman 冗余修正降低高度相关指标的重复计权，固定组间权重则避免指标数量较多的信号族自动占优。该分数用于汇总可观测质量信号，不代表质量指标对训练收益的因果贡献。

配比模型以 1M 配方实验训练，并使用同尺度留出和整簇留出检验。跨规模结果重点比较排序；10B/70B 的 Loss 为既有估算，仅用于一致性参考。图 2 概括上述步骤。




图 2 问题一的质量评价、配比预测与映射检验流程

6.1 数据审计与证据分级

附件 A 的两类数据解决不同问题：A1–A3 是七个质量域的文本质量信号；A4–A15 是 The Pile 的 17 域配方及 13 个验证域的 Loss；A16 仅提供跨域映射参考。各配方表与 Loss 表必须由 index 一一连接，不能依行号拼接。配比向量满足

$$\mathbf{p} = (p_1, \dots, p_{17}), \quad p_j \geq 0, \quad \sum_{j=1}^{17} p_j = 1. \quad (1)$$

按实际附件核查，A1、A2、A3 分别有 51 230、17 523、203 752 条原始记录。三表合计 272 505 条，其中 19 条结构或字段损坏、11 条来源可疑记录予以隔离，11 419 条为可验证的精确重复；有效去重并集为 261 056 条。A1 与 A2 的 arxiv 记录重叠 1 419 条，与 A3 的 github 记录重叠 10 000 条，因此抽样集和扩展集不是独立样本。旧字段模式审计中，modernbert_reasoning 与 modernbert_professionalism 分别发现 78、36 个非法列表元素，涉及 13、6 条已隔离记录；这里的元素次数不等于新增损坏记录数。通过审计仅表示符合当前结构及数值规则，不能独立证明数据来源真实性。

表中的“可评分来源行”保留同一文本的来源指针；真正用于拟合尺度、权重和域级汇总的是去重分析视图。A1 的 20 条隔离记录含 18 条结构或字段损坏、2 条待核实

表 1 质量信号附件的记录级审计结果

附件	原始行	可评分来源行	精确重复行	隔离行
A1 抽样集	51 230	51 210	0	20
A2 arxiv 扩展集	17 523	17 523	1 419	0
A3 github 扩展集	203 752	203 742	10 000	10
合计	272 505	272 475	11 419	30

可疑；A3 的 10 条分别为 1 条损坏和 9 条可疑。没有因扩展集缺少抽样集的辅助字段而补造记录。

A4/A5 的 512 组 1M 配方及 Loss 来自 RegMix 配方实验^[4]，仅用于训练和模型选择；A6/A7 的 256 组 1M、A8/A9 的 256 组 60M、A10/A11 的 64 组 1B 用于留出检验。A12/A13 与 A14/A15 分别包含 63 组配方及对应 Loss；其配方取自训练子集，Loss 是附件中的既有外推估算，不能充作新的直接实验。上述文件的校验值、排除记录指针与连接检查保存在实验元数据和审计表中。

6.2 从原始信号到综合质量分

6.2.1 指标语义与尺度统一

对有效记录 i 的第 j 项原始信号 x_{ij} ，先按字段语义转换为标量 $s_{ij} = T_j(x_{ij})$ 。四项 ModernBERT 六等级 logits 经稳定 Softmax 转成等级期望；fluency_en 取“流畅”类别概率，ad_en 取“无广告”类别概率；单元素列表取其唯一值。QuRater 的四个分量各自按分位参考尺度标准化后等权平均，保留其分量语义而不作等级 Softmax。文档词数和句数先取 $\log(1+x)$ ，其余标量按原值进入统一分位尺度转换。无字母词比例、大写字母比例、高频二元及三元字符比例按反向指标处理；词数、句数、数字字符比例和平均词长按预设正向口径计分，并以删除四项暂定指标的敏感性分析检验结果变化。

例如，对一项 ModernBERT 的六等级向量 $\ell_{i0}, \dots, \ell_{i5}$ ，令 $m_i = \max_r \ell_{ir}$ ，则

$$\pi_{ir} = \frac{\exp(\ell_{ir} - m_i)}{\sum_{t=0}^5 \exp(\ell_{it} - m_i)}, \quad s_i = \sum_{r=0}^5 \frac{r}{5} \pi_{ir}. \quad (2)$$

减去最大值避免指数溢出，等级期望落在 $[0, 1]$ 。QuRater 的四个分量分别按有效去重并集的分位参考区间截尾、缩放，再取算术平均。这样处理保留了各分量的独立语义；对格式不符或出现非有限元素的列表直接隔离，而不以均值插补。

令 a_j, b_j 为有效去重并集中标量信号的第 1 与第 99 百分位数。对合法但处于参考范围以外的观测，按预设规则截尾；非法值已先在审计阶段隔离。统一后的“越高越好”指标为

$$z_{ij}^+ = \frac{\min\{\max(s_{ij}, a_j), b_j\} - a_j}{b_j - a_j}, \quad z_{ij} = \begin{cases} 1 - z_{ij}^+, & j \text{ 为反向指标,} \\ z_{ij}^+, & \text{其他指标.} \end{cases} \quad (3)$$

当 $a_j = b_j$ 时将该常量指标标记并以零贡献处理。A1–A3 使用同一参考尺度，不在扩展集上重新拟合。附件 A 汇总原始附件用途，核心实现见附件 B。

冻结实验实际以有效去重并集拟合上述分位参考尺度和组内权重；最初的建模设计拟仅用 A1 拟合后应用于 A2/A3。因此，报告的是并集固定尺度下的同域对照，不能把 A2/A3 的评分解释为对纯 A1 拟合规则的独立外推验证，也没有在写作阶段改动实验结果。

表 2 22 项质量信号的转换规则概览

信号族	项数	标量化方法	方向口径
ModernBERT	4	六等级 logits 的稳定 Softmax 期望	正向
FineWeb-Edu	1	单元素列表取值	正向
流畅度、广告判别	2	分别取“流畅”与“无广告”类别概率	正向
QuRater	1	四分量分别分位缩放后等权平均	正向
DSIR	3	原标量直接参与统一尺度转换	正向
语言及结构信号	11	词数、句数先 $\log(1+x)$ ；其余按原标量	四项反向；四项正向 暂定

6.2.2 语义分组下的权重分配

22 项信号固定分为模型及元评分组（8 项）、DSIR 分布价值组（3 项）和语言及文档结构组（11 项）。这是一种预先规定的评价结构，避免仅由全体指标的统计离散程度决定三类信息的相对份额。各组内部仍按熵差异和相关冗余计算权重。对组 G_g 内第 j 项指标，在 $n = 261\,056$ 条有效去重记录上定义

$$P_{ij} = \frac{z_{ij}}{\sum_{h=1}^n z_{hj}}, \quad d_j = 1 + \frac{1}{\ln n} \sum_{i=1}^n P_{ij} \ln P_{ij}, \quad (4)$$

$$R_{j|g} = \frac{1}{|G_g| - 1} \sum_{k \in G_g, k \neq j} (1 - |\rho_{jk}|), \quad u_{j|g} = \frac{d_j R_{j|g}}{\sum_{k \in G_g} d_k R_{k|g}}, \quad (5)$$

其中 ρ_{jk} 为有符号 Spearman 相关，熵计算约定 $0 \ln 0 = 0$ ；常量指标和零分母有确定性退化处理。本次实测三个组均未触发等权回退。三个组各占总权重的 $1/3$ ，即

$$S_{ig} = \sum_{j \in G_g} u_{j|g} z_{ij}, \quad Q_i^H = \frac{100}{3} \sum_{g=1}^3 S_{ig}, \quad Q_d^H = \frac{1}{n_d} \sum_{i \in d} Q_i^H. \quad (6)$$

因此 $0 \leq Q_i^H \leq 100$ 。权重由指标分布差异及统计冗余共同确定。领域均值以记录为单位，不含 token 加权；95% 区间由固定种子 7 的 500 次域内重抽样给出。

三个组的总权重严格各为 $1/3$ ，而各组内部的指标权重由数据确定。实际最大单项全局权重为 dsir_math 的 0.1574；数字字符比例的权重为 0.1360。DSIR 三项之间相关性较高，预先规定的整组 $1/3$ 质量份额使其中单项仍获得较大权重。

为完整展示抽样集与扩展集对照，表 4 列出相同固定尺度和权重下各来源的域级结果。A1 中与扩展集对应的 arxiv、github 样本分别为 1,419 和 10,000 条；A2、A3 的扩展视图分别为 17,523 和 203,742 条。相同 ID 的重叠记录在评分参数拟合时只计一次，在来源视图比较时保留来源标记，因此该表展示来源范围差异，不把重叠记录解释为独立验证。

由表 3 可见，在当前评价规则下七领域均值的次序为 stackexchange、arxiv、commoncrawl、c4、wikipedia、github、book；book 仅有 171 条有效记录，区间明显更宽。

6.3 评分规则的敏感性检验

6.3.1 指标方向与权重扰动

为检验规则依赖性，另计算剔除四项方向暂定指标的 Q^{H-4} 和组内等权的 Q^{H-eq} 。 Q^{H-4} 与主评分的全样本 Spearman 为 0.8693，Top 1% 集合重合率仅 0.1536，七个领域




图3 前12项指标的旧版与当前全局权重比较

表3 有效去重并集的七领域质量评分（分）

质量域	样本数	分层主 Q^H	95% 区间	旧版 Q
stackexchange	9 998	64.82	[64.71, 64.93]	46.04
arxiv	17 523	64.20	[64.06, 64.35]	61.50
commoncrawl	9 636	63.61	[63.48, 63.72]	46.62
c4	10 000	62.28	[62.17, 62.38]	44.26
wikipedia	9 986	60.21	[60.10, 60.32]	41.26
github	203 742	54.06	[54.03, 54.08]	32.98
book	171	45.85	[44.31, 47.25]	51.03

表4 A1 抽样集与 A2/A3 扩展集的分领域质量评分对照

领域	去重并集 n/Q^H	A1 n/Q^H	对应扩展集 n/Q^H
arxiv	17,523 / 64.20	1,419 / 64.73	A2: 17,523 / 64.20
github	203,742 / 54.06	10,000 / 54.07	A3: 203,742 / 54.06
book	171 / 45.85	171 / 45.85	—
c4	10,000 / 62.28	10,000 / 62.28	—
commoncrawl	9,636 / 63.61	9,636 / 63.61	—
stackexchange	9,998 / 64.82	9,998 / 64.82	—
wikipedia	9,986 / 60.21	9,986 / 60.21	—




图 4 七领域分层综合质量分及域内重抽样 95% 区间

中五个名次发生变化，表明领域排序对指标方向仍较敏感。分层后数字字符比例的全局权重由旧版 0.2520 降至 0.1360，但新方案仍保留其方向敏感性。

为显示权重重分配的具体指标，表5列出五项代表性指标在分层主评分与旧版全局熵权下的权重。主方案将三个语义组的总权重固定为相等，再在组内按熵信息差异和 Spearman 冗余分配；权重差异反映评价规则变化，不解释为训练效果的因果贡献。

表 5 部分代表性指标在两套评分规则下的权重

指标	分层主评分	旧版全局熵权
dsir_math	0.1574	0.0047
rps_lines_numerical_chars_fraction	0.1360	0.2520
dsir_books	0.0912	0.0044
dsir_wiki	0.0847	0.0044
modernbert_reasoning	0.0830	0.0898

两域扩展后的平均分与抽样视图处在相近量级，但 A1 的这些记录包含在对应扩展集内，差异只是同源样本范围变化，并非独立验证。相较而言，指标方向和组内赋权的变动对排序的影响更大，见表 6；TOPSIS 仅作为多指标排序对照^[1]。

表 6 综合评分规则的全量样本敏感性

评分规则	与主 Q 的 Spearman	Top 1% 重合	最高领域
分层主评分	1.0000	1.0000	stackexchange
删除四项方向暂定指标	0.8693	0.1536	c4
组内等权	0.9130	0.4401	commoncrawl
旧版全局熵权与冗余修正	0.8653	0.4638	arxiv
TOPSIS 对照	0.7681	0.4339	arxiv

表6给出样本层排序的一致性，图 5进一步把同一批冻结结果投影到领域层。热力图中的颜色表示名次，单元格同时保留对应领域分，因而能够区分“分数整体平移”和“领域次序改变”。主评分下 stackexchange 排第 1，删除四项暂定方向后降至第 3，旧版

熵权方案下降至第 4；c4 则由主评分第 4 上升到删除四项后的第 1。book 在主评分中最低，但在旧版熵权和 TOPSIS 中均列第 2。上述变化不是抽样噪声造成的，因为各列使用相同去重并集；它反映的是方向设定、组间份额和补偿规则的结构差异。

因此，领域质量分适合用来描述“在给定评价规则下哪些指标组合更突出”，不适合脱离规则直接称为领域的客观质量真值。分层主评分被固定为主口径，是因为它事先限制三个语义组的总份额，避免高度相关的 DSIR 指标仅凭数量或方差占据全部权重；但这一设计选择仍需与其敏感性结果同时报告。




图 5 五套冻结评分规则下的七领域得分与名次敏感性

6.3.2 质量冲突的识别与比较

不同质量信号对同一文本给出不同评价，属于评价维度分歧。消解规则是：先按指标语义统一方向，以三个语义组等权、组内熵差异与相关冗余加权得到 Q_i^H ；再用下述三类 C_i 标记分歧强度和来源。 C_i 用于解释和比较，不作为额外惩罚项，也不删除结构有效样本；只有审计确认的损坏记录进入隔离。复用式 (3) 的同一矩阵，并行计算三种互补指标：

$$C_i^W = \frac{\sum_{j < k} w_j w_k |z_{ij} - z_{ik}|}{\sum_{j < k} w_j w_k}, \quad w_j = \frac{1}{3} u_{j|g(j)}, \quad (7)$$

$$C_i^E = \frac{1}{\binom{22}{2}} \sum_{j < k} |z_{ij} - z_{ik}|, \quad \binom{22}{2} = 231, \quad (8)$$

$$C_i^G = \frac{|S_{i1} - S_{i2}| + |S_{i1} - S_{i3}| + |S_{i2} - S_{i3}|}{3}. \quad (9)$$

前两式分别刻画按主评分权重和不加权的指标对差异；第三式只考察预先固定的三语义组之间是否相互矛盾。三个数均位于 $[0, 1]$ ，并不互为替代。以 A1 合格记录的第 85、90、95 百分位数分别确定各式阈值，然后把同一阈值应用到 A2、A3，不按扩展集重新定阈。

设 $\tau_\alpha^{(m)}$ 为 A1 上方法 m 的 α 分位阈值，则领域 d 的高分歧率按

$$CR_{d,\alpha}^{(m)} = \frac{1}{n_d} \sum_{i \in d} \mathbf{1}\{C_i^{(m)} > \tau_\alpha^{(m)}\} \quad (10)$$

计算。第 90 百分位的三个固定阈值分别为 $\tau_{0.90}^W = 0.4823$ 、 $\tau_{0.90}^E = 0.4285$ 和 $\tau_{0.90}^G = 0.5062$ 。不同方法的数值尺度不同，因此只能在各自固定阈值内比较 A1 与扩展集的率。

表 7 A1 固定第 85、90、95 百分位阈值下的分域高分歧率

数据视图与领域	阈值	C^W	C^E	C^G
A1-arxiv	85%	0.1142	0.1247	0.1360
A1-arxiv	90%	0.1092	0.1078	0.1339
A1-arxiv	95%	0.0973	0.0613	0.1261
A2-arxiv	85%	0.1229	0.1341	0.1481
A2-arxiv	90%	0.1162	0.1148	0.1415
A2-arxiv	95%	0.1036	0.0590	0.1325
A1-github	85%	0.2273	0.1636	0.3308
A1-github	90%	0.1623	0.1145	0.2381
A1-github	95%	0.0881	0.0709	0.1316
A3-github	85%	0.2266	0.1624	0.3330
A3-github	90%	0.1639	0.1159	0.2416
A3-github	95%	0.0910	0.0704	0.1353

三种分歧量均在 A1 上分别以第 85、90、95 百分位确定阈值，并将同一数值应用于 A2/A3。完整阈值如下；三个分位口径下的分域冲突率均已计算，主文以第 90 百分位作代表展示。

表 8 A1 上三类质量分歧指标的固定阈值

分位数	加权指标对 C^W	等权指标对 C^E	语义组间 C^G
85%	0.4738	0.4165	0.4932
90%	0.4823	0.4285	0.5062
95%	0.4942	0.4459	0.5258

抽样集与对应扩展集的同域率接近，但两者包含重叠记录，不能称为独立外部验证。三种分歧指标两两 Spearman 相关为 0.507–0.825；A1 第 90 百分位高分歧样本的两两重合率仅为 0.395–0.709，说明“高分歧文本”的识别依赖评价口径。以 A1 的同一批加权高分歧样本计算指标对贡献，数字字符比例相关指标对占加权贡献 30.6%，占未加权原始差异 11.1%。因此该信号在旧版分析中的突出地位有明显的权重放大成分，不能仅按加权排序给出单一成因。语义组间差异用于解释模型评分、DSIR 信号与语言结构信号何处不一致；合法高分歧记录保留在质量评分和后续分析中。

进一步把指标对分歧拆为可复算贡献：在同一个高分歧集合 $\mathcal{H}$ 上，对 $j < k$ 定义

$$H_{jk}^W = \frac{1}{|\mathcal{H}|} \sum_{i \in \mathcal{H}} \frac{w_j w_k |z_{ij} - z_{ik}|}{\sum_{a < b} w_a w_b}, \quad H_{jk}^E = \frac{1}{|\mathcal{H}|} \sum_{i \in \mathcal{H}} \frac{|z_{ij} - z_{ik}|}{231}. \quad (11)$$

对所有 231 对求和便分别还原该集合的平均 C^W 、 C^E 。将涉及数字字符比例的所有 H_{jk} 求和并除以对应总体贡献，得到上述 30.6% 与 11.1% 的对照。指标结构方面，以 $d_{jk} = \sqrt{(1 - \rho_{jk})/2}$ 将有符号 Spearman 相关转为距离，在 2–7 簇、average/complete/single 三种连接方式下比较 18 组聚类；轮廓系数介于 0.1362 与 0.2678。聚类结果用于检视指标结构，正式综合评分和冲突解释仍使用预先定义三个语义组。

6.4 配比对验证 Loss 的预测

6.4.1 数据划分与预测器选择

设第 i 个配方的 17 维向量为 $\mathbf{p}_i$ ，13 个验证域的 Loss 为 L_{ik} 。对每个目标 k ，建立参考域参数化的岭回归基准^[2]及全维 LightGBM 回归模型^[3]：

$$\hat{L}_{ik}^R = \beta_{0k} + \sum_{j=1}^{16} \beta_{jk} p_{ij}, \quad \hat{L}_{ik}^{\text{GBM}} = f_k(\mathbf{p}_i), \quad k = 1, \dots, 13. \quad (12)$$

由于式 (1) 使完整 17 维线性项与截距共线，岭回归省略一个参考域；其输入标准化只在每个训练折内拟合。LightGBM 为每个 Loss 目标单独拟合一棵树集成。模型选择仅使用 A4/A5 的 512 组训练配方，采用种子 7、五折十次重复交叉验证；各目标的归一化误差以训练 Loss 标准差为分母，宏平均为

$$\text{NRMSE}_{\text{macro}} = \frac{1}{13} \sum_{k=1}^{13} \frac{\sqrt{n^{-1} \sum_i (L_{ik} - \hat{L}_{ik})^2}}{s_k^{\text{train}}}. \quad (13)$$

训练内该指标为 Ridge 0.6280、LightGBM 0.1662；LightGBM 在 13 个目标及十次重复比较中均较优，因而按预定规则冻结为主预测模型，没有使用 A6/A7 重新调参。

LightGBM 使用受限树复杂度和正则化控制小样本拟合，冻结配置为 220 棵树、学习率 0.03、最大深度 4、最多 15 叶、叶节点最少 20 个样本。两类模型采用相同评估目标与折分；留出集不参与调参。对应的模型实现列于附件 B。

表 9 同尺度留出检验与配方簇留出检验的预测误差

验证方式	Ridge	LightGBM
训练内重复交叉验证：宏 NRMSE	0.6280	0.1662
1M 留出集：宏 NRMSE	0.5770	0.1309
1M 留出集：汇总 R^2	0.5431	0.9817
十簇 GroupKFold：宏 NRMSE	0.8532	0.2391

为展示 13 个目标上的完整留出表现，表 10 逐一列出冻结 LightGBM 在 1M 留出集上的 RMSE、MAE、 R^2 与 Spearman 排序相关。

在 60M 与 1B 留出集上，模型跨规模绝对 Loss 有系统偏移，故重点考察配方排序：LightGBM 的 13 目标平均 Spearman 分别为 0.9836 和 0.9487。10B、70B 的对应值为 0.5411、0.4509，对应附件既有估算表的一致性检验。

同一配方在不同参数规模上的绝对 Loss 可发生基线平移或尺度变化。因此，表 11 所列排序衡量的是相对配方优劣能否迁移，不能替代跨规模 Loss 的重新校准。10B/70B 的估算配方与训练配方重合，也没有新增独立配方覆盖。

同尺度留出测试可能因测试配方靠近训练配方而取得较好结果。为区分这一情形与真正的配方迁移，进一步做最近邻距离分层和整簇留出验证；两项检验均不重新选择模型超参数。

令 $\mathcal{P}_{\text{train}}$ 为训练配方集合，测试配方的距离为

$$d(\mathbf{p}, \mathcal{P}_{\text{train}}) = \min_{\mathbf{q} \in \mathcal{P}_{\text{train}}} \|\mathbf{p} - \mathbf{q}\|_2. \quad (14)$$

对训练配方本身计算该量时排除同一行。平均最近邻距离在训练、1M/60M、1B 分别为 0.1706、0.1716、0.2153；1B 配方整体更远，但仍需与训练支持范围比较。1M 留出集

表 10 冻结 LightGBM 在 1M 留出集上的逐目标表现

验证域	RMSE	MAE	R^2	Spearman
arxiv	0.1100	0.0685	0.9801	0.9954
freelaw	0.0647	0.0443	0.9923	0.9967
pubmed_central	0.1056	0.0820	0.9841	0.9920
wikipedia_en	0.0716	0.0506	0.9828	0.9947
dm_mathematics	0.2233	0.1250	0.9788	0.9701
github	0.0971	0.0680	0.9889	0.9969
stackexchange	0.0751	0.0513	0.9872	0.9959
gutenberg_pg_19	0.0749	0.0532	0.9721	0.9918
pile_cc	0.0574	0.0435	0.9679	0.9885
ubuntu_irc	0.1510	0.1038	0.9771	0.9679
hackernews	0.0624	0.0470	0.9656	0.9866
pubmed_abstracts	0.0802	0.0569	0.9802	0.9932
uspto_backgrounds	0.0533	0.0391	0.9891	0.9919

表 11 冻结 LightGBM 的跨规模配方排序检验（13 目标平均）

配方与 Loss 表	证据性质	Spearman	最低 Loss 的 Top-10 重合率
60M 检验	真实留出	0.9836	0.7692
1B 检验	真实留出	0.9487	0.8923
10B 参考	附件既有估算	0.5411	0.6000
70B 参考	附件既有估算	0.4509	0.5615

每个距离四分位均有 64 个配方，其冻结 LightGBM 表现见表 12。各距离组的误差没有随最近邻距离单调增大；距离统计用于刻画配方空间支持，不足以单独预测某一配方的误差。

最近邻距离用于描述配方的几何支持。十簇检验先只用 A4 配比拟合 KMeans，再由 GroupKFold 将整簇分到训练侧或验证侧；在固定旧版超参数的条件下重新拟合每折模型。Ridge 宏 NRMSE 从随机重复验证的 0.6280 增至 0.8532，LightGBM 从 0.1662 增至 0.2391；后者仍较优，同时量化了随机划分相对整簇留出的误差差异。

6.4.2 单域扰动与组合响应

为量化份额改变的模型响应，对领域 j 增加 $\delta \in \{0.01, 0.03, 0.05\}$ ，从其余可调整领域按原占比等比例扣减，并检验非负与行和约束。对满足训练配方最近邻支持门槛的

表 12 1M 留出集按配方距离四分位的 LightGBM 表现

距离组	平均最近邻距离	宏 NRMSE	汇总 R^2
最近 25%	0.0958	0.1612	0.9766
第二四分位	0.1569	0.1160	0.9848
第三四分位	0.1945	0.1166	0.9830
最远 25%	0.2394	0.1212	0.9806




图 6 训练及留出配方的最近邻距离分布

样本，定义第 k 个验证域的平均有限替代效应

$$\widehat{\text{AME}}_{jk}(\delta) = \text{mean}_{i \in \mathcal{S}_{j\delta}} \left[\widehat{L}_k(T_{j,\delta}(\mathbf{p}_i)) - \widehat{L}_k(\mathbf{p}_i) \right]. \quad (15)$$

双领域各增加 0.03 的组合响应写为

$$I_{jk}^{(m)} = \text{mean}_{i \in \mathcal{S}_{jk}} \left[\widehat{L}_m(T_{jk}(\mathbf{p}_i)) - \widehat{L}_m(T_j(\mathbf{p}_i)) - \widehat{L}_m(T_k(\mathbf{p}_i)) + \widehat{L}_m(\mathbf{p}_i) \right]. \quad (16)$$

这给出了 17 个单域、136 个领域对在 13 个 Loss 目标上的模型预测量。双域扰动与各单域扰动的扣减来源集合并不完全相同，因此式 (16) 表示给定再分配规则下的有限差分；训练支持不足的位置保持缺失。

支持范围由训练配方留一最近邻距离的第 95 百分位固定，为 0.2600。在 17 个单域扰动都可行且各扰动配方均处于该范围内的共同样本上， $\delta = 0.01, 0.03, 0.05$ 分别保留 481、475、472 组配方。这样的共同子集使各领域的响应可以在相同基线上比较；下式中的 $\widehat{\text{AME}}_{jk}$ 按式 (15) 计算，但将均值集合统一替换为该共同样本。为消除 13 个 Loss 目标的尺度差异，以训练集各目标标准差 s_k^{train} 定义等权汇总响应

$$\widehat{\Delta J_j}(\delta) = \frac{1}{13} \sum_{k=1}^{13} \frac{\widehat{\text{AME}}_{jk}(\delta)}{s_k^{\text{train}}}. \quad (17)$$

负值表示在这条替代路径上，预测的平均标准化 Loss 降低。将冻结 LightGBM 在 $\delta = 0.03$ 、475 组共同支持配方上的 13 项逐目标 AME 代入式 (17)，得到表 13。

表 13 共同支持配方上部分单域份额增加 0.03 的预测响应

降低汇总 Loss 的领域	$\widehat{\Delta J_j}$	提高汇总 Loss 的领域	$\widehat{\Delta J_j}$
ubuntu_irc	-0.0895	enron_emails	+0.0026
stackexchange	-0.0873	europarl	+0.0064
hackernews	-0.0833	philpapers	+0.0077

表中仅列出本次局部响应的两端例子；绝大部分领域的响应和全部 13 个目标的原始 AME 保存在结构化结果中。由于增加一个领域必然减少其他领域，该量表示份额替代的联合结果。136 对领域的组合差分同时受扣减路径与共同支持样本量影响，用于比较局部响应。




图 7 双领域份额扰动下的标准化 Loss 联合响应

6.5 质量映射的覆盖范围

A16 的 17 个配方域中，仅三个 **direct** 和三个 **near_direct** 域进入可靠映射集合 M ；其余 11 个 **inferred** 域不补填质量分。对任一配方定义可靠映射覆盖率及覆盖部分的质量代理

$$c_i = \sum_{j \in M} p_{ij}, \quad Q_i^{\text{mapped}} = \frac{\sum_{j \in M} p_{ij} Q_{d(j)}^H}{c_i}, \quad c_i > 0. \quad (18)$$

当 $c_i = 0$ 时该代理缺失；当 $c_i < 1$ 时，它不是完整 17 域配方的质量分。训练集平均覆盖率为 0.5646，仅 507/512 个配方可计算；1M 留出集平均覆盖率为 0.5690。覆盖率至少 0.20、0.40、0.60 的阈值均在实验前固定，并在相同样本、相同五折上比较 $\text{Ridge}(\mathbf{p})$ 与 $\text{Ridge}(\mathbf{p}, Q^{\text{mapped}})$ 。各配方表的映射覆盖情况见表14。

表 14 六个可靠映射域在各配方表中的覆盖率

配方表	可计算数/总数	平均覆盖率	中位数	第 10–90 百分位
训练 1M	507/512	0.5646	0.6004	[0.1502, 0.9408]
检验 1M	256/256	0.5690	0.5830	[0.1694, 0.9460]
检验 60M	256/256	0.5690	0.5830	[0.1694, 0.9460]
检验 1B	64/64	0.6226	0.6476	[0.4411, 0.7995]
估算参考 10B/70B	63/63	0.5435	0.5714	[0.1255, 0.9315]

表 14中的“可计算”只要求 $c_i > 0$ ，而中位覆盖率约 0.60 表明相当一部分配比质量未被六域代理描述。因此在不同覆盖率门槛下重新比较模型，并始终用同一筛选样本和同一交叉验证折分计算有无 Q^{mapped} 的差值。

在全部 507 个可映射训练配方上，加入新主 Q^{mapped} 后，交叉验证汇总 R^2 由 0.51810

表 15 可靠映射覆盖率门槛下加入质量代理的汇总 R^2 增量

覆盖率门槛	训练数	1M 留出数	训练内 CV 增量	1M 留出增量
$c_i > 0$	507	256	+0.0009	-0.0010
$c_i \geq 0.20$	445	220	+0.0016	+0.0007
$c_i \geq 0.40$	354	180	-0.0001	-0.0002
$c_i \geq 0.60$	257	123	+0.0020	-0.0025

变为 0.51902，增量仅 +0.00092；1M 留出集汇总 R^2 由 0.54336 变为 0.54238。覆盖率阈值变化后，改善方向并不一致。为检验这一微小变化是否仅来自添加一个由 $\mathbf{p}$ 派生的特征，固定配比、覆盖率、折分和岭回归候选参数，把六个质量域的 Q_d 随机错位对应 1000 次。真实映射增量位于置换分布第 14.6 百分位，单侧经验 $p = 0.854$ ；旧版 Q 的对应结果为第 64.7 百分位、 $p = 0.354$ 。两种 Q 均未显示真实对应关系明显优于随机领域赋值，因此正式 Loss 主模型保持只输入 $\mathbf{p}$ 。

具体地，每次抽取非恒等排列 π ，仅把式 (18) 分子中的六个 $Q_{d(j)}$ 改为 $Q_{d(\pi(j))}$ ，配比、覆盖率和折分保持不变。令 Δ_π 为加入置换代理后的训练内汇总 R^2 增量，真实映射增量为 Δ_{real} ，采用

$$\hat{p}_{\text{cmp}} = \frac{1 + \#\{\pi : \Delta_\pi \geq \Delta_{\text{real}}\}}{1000 + 1} \quad (19)$$

作单侧经验比较。1000 次抽样中有 543 个不同的非恒等排列；重复排列仍按实际抽样次数保留。表 16 表明，真实对应关系的增益未处于置换分布的高端，映射诊断未显示稳定的独立预测增益。

表 16 真实映射与领域质量置换的训练内预测增量

质量评分版本	真实 ΔR^2	置换均值	真实百分位	单侧经验 p
分层主 Q^H	+0.000921	+0.00510	0.146	0.854
旧版全局熵权 Q	+0.006184	+0.00512	0.647	0.354

覆盖率门槛改变后，质量代理的预测增量有正有负；置换分布也未显示真实映射显著优于随机领域赋值。两类诊断共同支持将 Q^{mapped} 保留为描述性代理，而不加入正式 Loss 主预测器。

6.6 审计样本的纳入范围

第一问的原始表同时承担“展示来源事实”和“供模型拟合”两种用途。为了让读者追查某个评分或排除决定，审计保留按文件的原始完整来源视图，并另建去重后的分析视图。A1 是抽样记录，A2/A3 是同源扩展记录；若直接合并三个文件计算均值，重复的 arxiv 与 github 文本会在权重拟合中获得两次计数。反之，若只保留扩展文件而丢弃 A1，又会失去 A1 中可能存在的辅助字段与抽样来源指针。两种视图同时保留，是为了既不重复统计也不抹去证据。

记录状态的判定先于异常分析。无法解析的 JSON、列表元素非法或关键数值字段无效属于可确认损坏；来源或内容可疑但结构合法时，只能标记为待核实，而不能由离群分数直接宣布“伪造”。去重则先找相同 ID 的候选，再比较可用共有字段；扩展文件不带有 A1 的部分辅助字段属于设计上的结构性缺失，不由此创造缺失值或认定冲突。最终 19 条结构损坏与 11 条可疑记录隔离；11419 条可验证精确重复只在分析视图中计一次。可评分来源行与有效去重并集数因此分别为 272475 和 261056。




图 8 六个可靠映射域的质量对应关系置换诊断

A4–A15 的配比表与 Loss 表按 index 一一对应。索引连接允许检查是否存在缺失键、重复键或错位行，而用行序拼接无法发现一张表重新排序后的隐蔽错配。训练 A4/A5 的 512 个键及留出 A6–A11 的 256、256、64 个键均完成一一连接；10B/70B 配方是训练子集，距离为零只说明配方相同，不会把附件中既有的估算 Loss 变成新的训练实验。17 个配比列始终作为输入，即使其中四个领域没有对应的单独验证 Loss 列，也不能因此在建模时把其训练份额删除。

6.7 指标方向的设定及其解释边界

质量评分从语义转换开始，而不是从某个机器学习模型自动学习“好坏”。六等级输出在确认其为有序 logits 后转换为等级期望；QuRater 的四个分量没有共同等级顺序，故分别缩放后合成。若把所有列表不加区分地送入 Softmax，会把无序维度误解释成等级概率。文档长度与句数的方向也不是逻辑上单调确定的：过短文本可能缺信息，过长文本可能重复或混杂。现有主规则给出暂定方向，并通过删除四项暂定指标直接测量排序会怎样改变。

三个语义组等权是一项明确的评价规则。若完全让 22 项指标的全局熵差异决定份额，数量较多或变异较大的信号族可能压过只有三项的 DSIR 组；反过来，三组各占三分之一也意味着组内某项可能获得较高总权重。数学上，令组内权重 $u_{j|g} \geq 0$ 且 $\sum_{j \in G_g} u_{j|g} = 1$ ，全局权重为 $w_j = u_{j|g}/3$ ，则

$$\sum_{j=1}^{22} w_j = \sum_{g=1}^3 \frac{1}{3} \sum_{j \in G_g} u_{j|g} = 1, \quad 0 \leq Q_i^H \leq 100. \quad (20)$$

这保证了分数尺度自洽，却不证明等组权是唯一正确的训练效用函数。全局最大单项权重为 dsir_math 的 0.1574，数字字符比例仍占 0.1360；所以主评分必须与等权、旧版全局权重及删除暂定指标的对照一并阅读。

删除四项方向暂定指标后，全样本 Spearman 仍为 0.8693，乍看较高；但 Top 1% 集合只重合 0.1536，七个领域有五个名次变化。两者并不矛盾：Spearman 由整个样本秩序决定，Top 集合只考察最靠近高分尾部的文本。若研究用途是选最优质的少量训练语料，Top 重合率比总体秩相关更直接；若用途是比较全量领域分布，则需要同时看均值和区间。不能因一个指标较稳定，就覆盖另一指标暴露的尾部不稳定。

域级区间由域内 500 次重抽样给出，只量化有效记录在当前评分规则下的均值波动。book 仅 171 条，区间 [44.31, 47.25] 远宽于 github 的 [54.03, 54.08]。这不表示 book

数据一定差，而是样本量与抽样构成使估计更不确定。域均值以记录等权，尚无一致可靠的 token 权重；若要把它当作实际训练语料质量，还需要知道各记录的 token 贡献与采样权重。

6.8 质量冲突下的样本保留

样本级“冲突”在本稿中称为评价信号分歧，主要回答不同指标对同一文本是否给出不一致的判断。加权指标对差异 C^W 继承主评分权重，能够指出会影响主分数的分歧；等权指标对差异 C^E 更接近“原始信号之间相距多远”；三语义组差异 C^G 则回答模型评分、分布价值和结构特征之间是否一致。三者不能互相替代，更不能与结构损坏状态混同。

表 17 同一 A1 第 90 百分位阈值下不同领域的高分歧率

领域	加权指标对	等权指标对	三语义组间
c4	0.2404	0.2827	0.0659
github	0.1623	0.1145	0.2381
commoncrawl	0.0093	0.0134	0.0114
book	0.1345	0.6257	0.0760

表17显示，c4 在指标对层面的分歧较多，但在三组汇总之间并不突出；github 的组间差异反而较大。book 的等权指标对高分歧率很高，却只有 171 条记录，需要同时看样本量与阈值适用性。若只给出一个“冲突率”，这些不同来源会被遮蔽。A1 固定阈值应用于 A2/A3 后，arxiv 与 github 同域率变化较小，但 A1 与扩展集重叠，所以仍只是同源范围对照。

在同一批 A1 加权高分歧文本上，涉及数字字符比例的指标对占加权贡献 30.6%，但占等权原始指标对差异只有 11.1%。因此“数字字符比例是冲突主因”这句话若不限定加权口径就会过度解释。该字段可能真实反映代码、公式或表格类文本的结构特征，也可能因评价方向暂定而放大分歧；附件不能单独判定。合法高分歧文本继续保留在评分和配比分析中，只有审计确认损坏或来源不可核实时才隔离。

6.9 质量代理在配比预测中的检验

LightGBM 在随机重复交叉验证和整簇留出中均优于 Ridge，但误差从 0.1662 升到 0.2391，表明新配方簇的预测更困难。1M 留出按最近邻距离四分位的误差并未单调增大，说明局部距离不是误差的唯一决定因素；完整单纯形几何、领域构成差异和跨规模检验共同影响预测表现。

单域扰动使用共同支持样本，是为了让领域间有限替代效应有可比基线。若领域 j 的扰动只对某一批配方可行、领域 k 的扰动只对另一批可行，直接相减会把样本组成差异误当成领域效应。即便使用相同的 475 个配方，增加 p_j 仍须从其他份额扣减；估计量描述的是这一条受约束的份额转移路径。改变扣减规则、基准配方或支持门槛，就可能得到不同响应。

质量代理 Q^{mapped} 由六个可靠对应域的 Q_a 与 p_j 计算，是已有配比的派生量。将其与全部 p_j 一同放入 Ridge 后，主分数的训练内 R^2 增量约为 0.0009，1M 留出性能略有下降；置换六域对应关系后，真实映射增益也未超过多数随机错配。现有映射因而没有提供稳定的独立预测增益。

6.9.1 质量评分与配比响应的数值核验

6.9.1.1 评分、权重与冲突指标核验

对任一经过合法性检查的指标，截尾及正反向变换使 $0 \leq z_{ij} \leq 1$ 。若三个组的内部权重分别非负且组内和为 1，则主质量分满足

$$Q_i^H = \frac{100}{3} \sum_{g=1}^3 \sum_{j \in G_g} u_{j|g} z_{ij} \in [0, 100]. \quad (21)$$

实现时先检查 $\sum_i z_{ij}$ 是否为零；若为零，则将该指标标记为常量或退化并退出有效权重集合。熵项采用连续延拓 $0 \log 0 = 0$ ；Spearman 相关若因常量列成为 NaN，则记录退化来源。本次实测三个组均未触发等权回退。

令加权指标对系数为

$$a_{jk} = \frac{w_j w_k}{\sum_{r < s} w_r w_s}, \quad a_{jk} \geq 0, \quad \sum_{j < k} a_{jk} = 1. \quad (22)$$

则 $C_i^W = \sum_{j < k} a_{jk} |z_{ij} - z_{ik}| \in [0, 1]$ 。在高分歧集合 $\mathcal{H}$ 上交换求和次序，得到

$$\sum_{j < k} H_{jk}^W = \frac{1}{|\mathcal{H}|} \sum_{i \in \mathcal{H}} C_i^W. \quad (23)$$

该恒等式用于核验指标对贡献与样本分歧均值是否闭合。本次 22 指标主权重下分母 $\sum_{j < k} w_j w_k$ 非零，闭合检查通过。A1 的第 85、90、95 百分位数作为固定候选阈值，并以相同数值应用于扩展集。

6.9.1.2 岭回归参数化与配比扰动

配比向量满足 $\sum_{j=1}^{17} p_j = 1$ 。若线性模型同时加入截距和全部 17 项，则截距列等于配比列之和，系数不唯一。预先固定参考域 r 并删除其显式列后，模型写为

$$\hat{L}_k(\mathbf{p}) = \beta_{0k} + \sum_{j \neq r} \beta_{jk} p_j. \quad (24)$$

岭惩罚用于控制小样本估计方差，正则化强度仅在 A4/A5 的训练折内选择。

给目标域 j 增加 δ 时，其余允许扣减的领域集合 R 按当前份额比例减少：

$$p'_j = p_j + \delta, \quad p'_k = p_k \left(1 - \frac{\delta}{\sum_{h \in R} p_h} \right) \quad (k \in R). \quad (25)$$

当 $\sum_{h \in R} p_h = 0$ 或 δ 超过可扣减质量时拒绝该扰动；其余情况下，各分量保持非负且总和仍为 1。双域计算与两次单域计算共享扣减规则。支持范围另由训练配方留一最近邻距离的第 95 百分位 0.2600 判定，从而将单纯形可行性与训练样本支持分开检查。

6.10 问题一主要结论

本问完成 A1–A3 的逐记录审计与去重、22 项信号语义转换和统一尺度评分，并以 500 次域内重抽样给出七域区间；同时比较六种评分规则、三类分歧量、85/90/95 百分位阈值及 18 组指标聚类方案。删除四项方向暂定指标后，Top 1% 重合率为 0.1536。配比部分以 17 维比例预测 13 个 Loss 目标，报告逐目标留出表现，并计算 17 个单域、136 个双域组合在支持样本上的响应；LightGBM 在 1M 留出集上的宏 NRMSE 为 **0.1309**，

整簇留出时为 **0.2391**。最后，A16 映射以覆盖率分层及 1,000 次置换检验评估质量代理的增量。

A16 仅覆盖六个可靠映射域， Q^{mapped} 未显示稳定独立增益。下文记 $Q_A \equiv Q^H$ ，但 Q_A 与 Q_B 不直接等同；第二问使用的候选配比响应文件仅通过内部自检，正式质量/配比接口仍需端到端验收。

七、 问题二模型的建立与求解

经典标度律以幂律项描述参数量和训练数据量增加时 Loss 的经验性下降，并以 E 表示在该模型设定下未被两项规模效应解释的基线；正指数 α, β 对应边际收益随规模增加而递减的曲线形态^[5-6]。Chinchilla 研究进一步说明，在给定训练算力下，参数与数据应联合权衡，而不能单独扩大模型规模。在此基准上加入质量和配比项，但只把它们解释为当前数据与参数化下的条件响应；幂律形式是经验模型，并不保证跨机制或任意规模外推成立。

7.1 经典标度律的基准拟合

经典基准写为^[5-6]

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad E, A, B, \alpha, \beta > 0, \quad (26)$$

其中 N 以十亿参数、 D 以十亿 token 计。B1 含 1176 个同一训练体系的检查点^[7]。拟合参数为 $(E, A, \alpha, B, \beta) = (1.68980, 0.35398, 0.33998, 1.24031, 0.27988)$ ；按模型规模整组留下的八折检验中，最大 RMSE 为 2.2023×10^{-4} 。相邻检查点存在轨迹相关性，故不采用随机行切分。




图9 B1 经典标度律的拟合与残差诊断

冻结 B1 参数后，B2–B5 的 RMSE 分别为 1.2431、0.0038、0.2927、0.1976，Spearman 分别为 0.7881、1.0000、0.9830、0.9588。B2 的整体偏移使原始 R^2 降至 -5.0728 ，单看绝对误差会混淆来源偏移与响应形状。为诊断两者，定义

$$R_{\text{off}}^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i - \mu)^2}{\sum_i (y_i - \bar{y})^2}, \quad \mu = \frac{1}{n} \sum_i (y_i - \hat{y}_i). \quad (27)$$

这里的 μ 只是诊断性平移量，不是已识别的来源参数。表18显示，B2 扣除整体偏移后形状拟合有所恢复；B4、B5 的改善有限；B10 与生成估算高度一致不构成独立验证；B8 仍表现较差。因此跨来源结果主要用于趋势核验，不把不同评测口径的绝对 Loss 直接合并。

表 18 跨来源预测的原始与偏移修正指标

来源与证据类型	n	R_{raw}^2	R_{off}^2	μ	RMSE (原始/修正)
B2 (半合成)	1029	-5.0728	0.3848	1.1784	1.2431 / 0.3956
B4 (跨模型族)	57	0.6045	0.8300	0.2210	0.2927 / 0.1919
B5 (文献汇总)	44	0.7306	0.7335	0.0206	0.1976 / 0.1965
B10 (估算基线)	128	1.0000	1.0000	-0.0006	0.0011 / 0.0009
B8 (半合成压力集)	984	-3.2768	-0.2378	-1.2377	1.4683 / 0.7899

7.2 质量项的通道设定与检验

先用固定 (N, D) 下质量层级间的损失振幅

$$A_Q(N, D) = \max_{Q_B} L - \min_{Q_B} L \quad (28)$$

定位质量项可能作用的通道。若质量只乘在 $D^{-\beta}$ 上, A_Q 对 N 不应有系统依赖。B6/B7 半合成网格的合并诊断为 $\log A_Q = -0.7837 - 0.1431 \log N - 0.0546 \log D$, 其中 N 指数为 -0.1431 ± 0.0116 ($p = 1.3 \times 10^{-15}$); 固定 D 的五档估计也均为负。该结果支持在候选函数中同时检查容量通道与数据通道, 但属于半合成网格上的结构证据, 而非真实干预的因果证明。

在该结构证据下, 以 B6 估计通道—加性质量模型

$$L_Q(N, D, Q_B) = \tilde{E} + \tilde{A}N^{-\alpha}e^{-\rho_N Q_B} + \tilde{B}D^{-\beta}e^{-\rho_D Q_B} - E_1 Q_B. \quad (29)$$

B6 参数点估计及区块 Bootstrap 区间见表19; 重抽样共成功 500 次, 并以 (N, D) 基础组为单位。 $\tilde{E}$ 与 E_1 的拆分依赖所采用的质量基准约定; 同时, E_1 与 ρ_D 存在补偿, 故不把单个参数解释成独立的物理机制。

表 19 B6 质量模型关键参数的区块 Bootstrap 区间

参数	点估计	2.5% 分位	97.5% 分位
$\tilde{E}$	1.7112	1.5864	1.8292
$\tilde{A}$	0.6519	0.5801	0.7277
α	0.2783	0.2540	0.3064
$\tilde{B}$	1.4207	1.3350	1.5298
β	0.2834	0.2249	0.3587
ρ_N	0.3555	0.3224	0.4075
ρ_D	0.1428	0.0761	0.2170
E_1	0.1027	0.0629	0.1355

质量模型与不含质量项的基线在相同数据层上的比较见表20。B7 原表 450 行中 360 行与 B6 重合, 故仅将去重后的 90 行作为新质量水平留出; 其基础 (N, D) 网格已在 B6 出现, 不能称为新规模外推。B8 的质量方向与 B6/B7 不一致: 按 B6 方向拟合时质量参数触及搜索下界, 反转 Q_B 后 RMSE 才明显改善。因而 B8 单独作为方向压力测试, 不并入 B6/B7 重新估计, 也不反转质量语义。

表 20 质量模型与无质量基线的分层检验

数据层	模型	n	RMSE	R^2
B6 五折组交叉验证	不含质量	360	0.12898	0.86028
B6 五折组交叉验证	质量模型	360	0.05021	0.97883
B7 新质量水平留出	不含质量	90	0.05896	0.96642
B7 新质量水平留出	质量模型	90	0.04146	0.98339
B8 校准层	质量模型	984	1.38289	-2.79376
B8 外推层	质量模型	720	1.27147	-2.98797

7.3 配比响应接口的支持范围

问题一配比响应以 13 个有验证损失的领域作为 M2 坐标，四个无对应验证损失的原始领域聚合为 other，参考域为 uspto_backgrounds。参考配方 $\mathbf{p}_0$ 取 A4 训练配方的逐域均值，不代表最优配方。对第 v 个验证目标定义相对对数响应

$$h_{p,v}(\mathbf{p}) = \log \hat{L}_v(\mathbf{p}) - \log \hat{L}_v(\mathbf{p}_0), \quad h_p(\mathbf{p}) = \frac{1}{13} \sum_{v=1}^{13} h_{p,v}(\mathbf{p}), \quad (30)$$

使 $h_{p,v}(\mathbf{p}_0) = h_p(\mathbf{p}_0) = 0$ 。交接材料提供了 M2 配比响应的候选接口，含 577 行响应记录及基准配方行；manifest 固定坐标与目标顺序、参考域、 $\mathbf{p}_0$ 、聚合口径和校验值。接口文件 SHA-256 为：

32d0a2f71016e60f7deeb0584637c1db
5038caa1d40cd6d13822b06705c759ef

逐目标 $h_{p,v}(\mathbf{p}_0) = 0$ 、 $\log \hat{L}_v(\mathbf{p}_0) = a_v$ 、等权聚合基准为零及落盘复读四项文件级自检均通过。这只能说明候选 M2 文件内部数值自治，不等同于正式 Q1→Q2 质量/配比接口或完整联合模型通过项目验收；问题一的 LightGBM 与此 M2 也不是同一预测器，前者的留出结果不能替 M2 背书。

基准配方的 14 组分量列于表21。四个没有对应验证 Loss 的原始配比域合并为 other；该参考配方是 512 条 A4 训练配方的均值，不是优化得到的最优配方。

表 21 候选 M2 接口采用的基准配方 $\mathbf{p}_0$

配比组	p_0	配比组	p_0
arxiv	0.1130	freelaw	0.0968
pubmed_central	0.1138	wikipedia_en	0.0751
dm_mathematics	0.0255	github	0.1107
stackexchange	0.0994	gutenberg_pg_19	0.0469
pile_cc	0.1195	ubuntu_irc	0.0196
hackernews	0.0117	pubmed_abstracts	0.0662
uspto_backgrounds	0.0756	other	0.0263

这里列出的是 M2 使用的 14 组坐标（13 个目标域加 other）；其原始 17 域参考配方来自 A4 的 512 行逐域算术均值，未归一化行和为 0.99988086，候选接口再按 manifest 口径归一化到单纯形。该点是训练设计的名义中心，不是最优配比。对照的等权点 $(1/17, \dots, 1/17)$ 虽通过最近邻半径判据（距离 0.2405），但到 A4 凸包的 L_1 距离为

0.2662，超过 95.7% 的 A6–A7 留出配方；因此以 A4 均值作为基准有更明确的凸包内支持依据。

候选 M2 在 A6–A11 留出配方上的响应指标及凸包支持数见表22。支持检查分别在 M2 的 13 维坐标、含参考域的 14 维坐标和完整 17 维原始配方空间进行。1M 与 60M 切片在完整空间中均无配方落入训练凸包，但高维凸包很薄，单凭“凸包外”不能断言样本比训练设计更极端或预测必然失效。独立最近邻诊断中，A4 训练配方留一距离的第 95 百分位为 0.2601；A6–A7 与 A8–A9 的最近邻距离中位数均为 0.1767、第 95 百分位均为 0.2510，各有 12/256 个配方超过该半径。设计空间的连续偏移量也显示，A6–A7 到 A4 训练凸包的 L_1 距离中位数为 0.0663、第 95 百分位为 0.2352，范围为 [0.0003, 0.4205]。因此，排序统计应与距离支持诊断并列解读，而不把 17 维凸包判据单独当作外推结论。A 端检验同样不能代替 B 端对迁移系数 λ_p 的识别。

表 22 候选 M2 的分层预测与三空间凸包支持检查

留出层	配方数	中心化 log RMSE	平均目标 Spearman	凸包内 (13 维)	凸包内 (14 维)	凸包内 (17 维)
A6–A7 (1M)	256	0.09185	0.8733	8	2	0
A8–A9 (60M)	256	0.09766	0.8731	8	2	0
A10–A11 (1B)	64	0.10012	0.8008	28	14	8

另以 A 端 1M 与 60M 的 256 组同配方留出作跨尺度对照。两档配方逐行一致，与训练配方没有重叠。聚合绝对损失差的回归斜率为 0.7622；相对对数响应的斜率随目标聚合定义为 0.9710 或 1.0415。绝对幅度的收缩主要随损失水平下降而变化，不能直接用于折减 λ_p 。该比较只有两个配对规模点，且配比表没有可分离的 N, D 字段，故不拟合连续衰减规律，也不用于估计 λ_p 或判定配比作用通道。候选 M2 的交互扩展在 A6–A7 上平均对数 RMSE 为 0.07512，主效应模型为 0.07546，13 个目标中 7 个改善；提升较小且目标间不一致，不能确认具体领域对的互补关系。

在 A6–A7 的 256 个配方上，等权 h_p 的第 5 百分位、中位数和第 95 百分位分别为 -0.03230 、 0.05549 、 0.12439 ；13 折留一目标敏感性下， p_{95} 范围为 0.09726 – 0.13612 ，其中剔除 dm_mathematics 的变化最大。以 $N = 1B$ 、 $D = 150B$ tokens、 $Q_B = 0.5$ 为情景点，使用全部 256 个留出配方时， $\lambda_p = 0.5, 1, 1.5$ 对应的 Loss 相对变化 $p_{05}/\text{中位}/p_{95}$ 分别为 $(-0.203\%, 0.356\%, 0.812\%)$ 、 $(-0.402\%, 0.722\%, 1.677\%)$ 、 $(-0.599\%, 1.099\%, 2.597\%)$ 。这些百分位含凸包外配方，是外推情景范围而非置信区间； λ_p 仍不可识别，不能作为优化变量。

按 13 个目标等权汇总后，仅看 13 维凸包内的 8 个配方， h_p 的 $p_{05}/\text{中位}/p_{95}$ 为 $0.02337/0.05926/0.07890$ ；该子集样本很少，数值仅作支持分层描述，不作为稳定总体估计。对问题一交接材料中的 272 个 $\delta = 0.02$ 份额转移点，更新基准后其到 A4 凸包的 L_1 距离中位数为 0.2662，范围为 $[0.2262, 0.3062]$ ；其中 239/272 个高于 A6–A7 留出配方距离的第 95 百分位 0.2352。故这些转移点属于比多数留出配方更远的条件情景，须与留出验证结果区分。

7.4 来源差异下的广义标度律

为显式纳入领域配比及其与质量的潜在交互，令

$$U_N = \tilde{A}N^{-\alpha}e^{-\rho_N Q_B}, \quad (31)$$

$$U_D = \tilde{B}D^{-\beta}e^{-\rho_D Q_B} \exp([\lambda_p + \theta_{Qp}(Q_B - Q_{\text{ref}})]h_p(\mathbf{p})), \quad (32)$$

$$L_s(N, D, Q_B, \mathbf{p}) = c_s + \tilde{E} + U_N + U_D - E_1 Q_B. \quad (33)$$

其中 c_s 表示来源差异， λ_p 是 A 到 B 的配比响应迁移情景， θ_{Qp} 描述质量变化是否改变配比响应；基准分析取 $\theta_{Qp} = 0$ ，并以 $\lambda_p \in \{0, 0.5, 1, 1.5\}$ 作敏感性网格。 $\mathbf{p} = \mathbf{p}_0$ 时配比指数为零。Form A 将配比乘子仅置于 U_D ，Form B 则将其扩展到两个可约通道；两者作为结构情景比较，现有 A/B 分离资料不足以识别哪一式是唯一真实结构。

问题一质量分 Q_A 与 B6–B8 质量变量 Q_B 的定义和尺度不同，不能因二者都可数值化便直接互换。可在共同语料或干预锚点补齐后估计 $Q_B = f(Q_A)$ ；当前没有共同锚点，故质量映射、 c_s 、 λ_p 及质量—配比交互均不作点估计。A 端内部跨规模响应只能支持配比形状的描述，B 端不含配比字段，不能验证 A 到 B 的因果迁移。

7.5 边际效应与弹性网格

在固定配比下，对式(33)求偏导，得到

$$\frac{\partial L}{\partial N} = -\frac{\alpha U_N}{N}, \quad \frac{\partial L}{\partial D} = -\frac{\beta U_D}{D}, \quad \frac{\partial L}{\partial Q_B} = -\rho_N U_N + [-\rho_D + \theta_{Qp} h_p(\mathbf{p})] U_D - E_1. \quad (34)$$

在 $N = 1$ （十亿参数）、 $D = 150$ （十亿 token）、 $Q_B = 0.5$ 、 $\lambda_p = \theta_{Qp} = 0$ 的代表点，预测 $L = 2.52538$ ， $R = L - \tilde{E} = 0.81415$ 。每增加 1B 参数、1B token 或一个 Q_B 单位，模型局部预测的损失变化量分别约为 -0.15190 、 -0.0006041 和 -0.34239 。有符号弹性 $\varepsilon_x = (x/R)\partial L/\partial x$ 分别为 $(-0.1866, -0.1113, -0.2103)$ 。这些数值是 B6 半合成模型在指定工作点的局部量，参数、token 与质量的边际单位不同，不能直接用导数绝对值排序。

为检查工作点依赖，在 $N \in \{0.07, 0.1, 0.3, 1, 3, 10, 30\}$ 、 $D \in \{10, 50, 150, 500, 2000\}$ 、 $Q_B \in \{0.2, 0.35, 0.5, 0.65, 0.8\}$ 的 175 个点上复算弹性。三项弹性在全部网格均为负，表示该拟合函数内增加参数、增加 token、提高质量均对应较低预测损失；但 $|\varepsilon_Q| > |\varepsilon_N| > |\varepsilon_D|$ 仅在 64/175 点同时成立。例如 $N = 0.07\text{B}$ 、 $D = 150\text{B}$ 、 $Q_B = 0.5$ 时， $|\varepsilon_N| = 0.2101 > |\varepsilon_Q| = 0.1832$ 。所以弹性排序不能推广为全局结论。

领域配比满足 $\sum_j p_j = 1$ ，提高一个域必然伴随其他域份额下降。令从供给域 k 向目标域 j 转移份额 δ ，则局部损失改善由 $-\partial L/\partial \delta$ 给出，取决于转移路径及 $h_p(\mathbf{p})$ 的梯度。主 M2 不含领域间显式交叉项；交互候选虽可用于比较，但留出改进有限，故只报告条件化的份额转移响应，不宣称已识别具体领域对的训练协同。

7.6 质量对规模的替代条件

固定 $D, \mathbf{p}$ 和目标损失，对 L 作隐函数求导可得

$$\left. \frac{dN}{dQ_B} \right|_{L, D, \mathbf{p}} = -\frac{\partial L/\partial Q_B}{\partial L/\partial N}. \quad (35)$$

在零交互情景的 $N = 1\text{B}$ 、 $D = 150\text{B}$ 、 $Q_B = 0.5$ 工作点，将质量提高至 0.6 并数值反解等损失参数量，得到 $N_1 = 0.7994\text{B}$ ，即该函数下的局部条件替代量约为 0.2006B 参数。它不包含质量处理成本，不能解释为现实数据清洗收益的通用换算。

进一步以训练 FLOPs 为投入单位，记 $C_N \simeq 6ND$ 为扩模成本， $C_Q(Q_B)$ 为质量提升成本，则每单位算力的预测损失改善效率为

$$\eta_N = \frac{\alpha U_N}{6ND}, \quad \eta_Q = \frac{-\partial L / \partial Q_B}{C'_Q(Q_B)}. \quad (36)$$

按指数型、幂函数型和对数渐进型三种预设质量成本函数，在 $D = 150B$ 、 $Q_B : 0.5 \rightarrow 0.6$ 下的等算力情景比较见表23。三种成本设定均给出提质的较大预测改善，但成本函数并非来自实际账单，故该结果仅为指定参数下的算力情景，不是货币成本结论或全局资源最优。

表 23 三种预设质量成本情景下的等算力比较

质量成本情景	提质额外算力	同算力扩模量	扩模带来的 $ \Delta L $	提质/扩模改善比
指数型	2.48×10^{19} FLOPs	0.0275B	0.0041	11.2
幂函数型	5.03×10^{19} FLOPs	0.0559B	0.0082	5.4
对数渐进型	4.62×10^{19} FLOPs	0.0514B	0.0076	4.1

7.7 问题二主要结论

本问完成了 B1 经典标度律拟合与按规模留组检验、B2–B5 跨来源趋势核验、B6 质量扩展估计及 B7 新质量水平留出、B8 方向压力测试、候选 M2 配比响应的支持诊断、配比跨尺度对照、边际弹性网格以及质量—参数量的等损失和等算力比较。B8 的独立拟合还显示，沿原始 Q_B 方向时 ρ_N, ρ_D, E_1 均触及 0.0010 的搜索下界，RMSE 为 0.6675；以 $1 - Q_B$ 重拟合后 RMSE 降至 0.0701。该反向编码仅是解释 B8 与 B6/B7 冲突的一种候选，不足以证明真实质量方向应反转，因此 B8 仍单列为压力测试。综合结果支持：在 B6/B7 半合成范围内，质量扩展模型较无质量基线有更低预测误差；参数、token 和质量局部作用随工作点而变；领域份额效果必须连同供给域和转移路径解释。

同时，A/B 数据没有共同的 $N, D, Q, \mathbf{p}, L$ 观测； $Q_A \rightarrow Q_B$ 映射、来源偏移、配比迁移 λ_p 和 $Q \times p$ 交互 θ_{Qp} 尚未由现有数据识别。候选 M2 文件的内部自检通过，但正式 Q1→Q2 质量/配比接口及完整联合模型尚未端到端验收；它只能为后续情景计算提供候选输入，不能代替共同质量锚点及质量等级 $\times$ 配方交叉桥接实验。因此完整广义式仍按模块估计和显式情景连接，结论限定于现有数据及其支持范围。

7.7.1 广义标度律边际效应与等损失替代推导

对式(33)，将 U_N, U_D 视为式(34)中的两个可约通道，并在求偏导时固定其余变量，可得

$$\frac{\partial L}{\partial N} = -\frac{\alpha U_N}{N}, \quad \frac{\partial L}{\partial D} = -\frac{\beta U_D}{D}, \quad (37)$$

$$\frac{\partial L}{\partial Q_B} = -\rho_N U_N + [-\rho_D + \theta_{Qp} h_p(\mathbf{p})] U_D - E_1, \quad \frac{\partial L}{\partial h_p} = [\lambda_p + \theta_{Qp}(Q_B - Q_{\text{ref}})] U_D. \quad (38)$$

若 $\theta_{Qp} = 0$ 且质量提高使 $\partial L / \partial Q_B < 0$ ，沿等损失曲线 $dL = 0$ 、固定 $D, \mathbf{p}$ ，有

$$\frac{dN}{dQ_B} = -\frac{L_{Q_B}}{L_N}, \quad \frac{d \log N}{dQ_B} = -\frac{L_{Q_B}}{N L_N}. \quad (39)$$

由于 $L_N < 0$ ，若 $L_{Q_B} < 0$ ，则 $dN/dQ_B < 0$ ，即该模型条件下提高质量可在局部抵消部分参数规模。该导数依赖工作点、配比情景及质量函数，不包含质量处理成本；有幅度的替代应直接求解式(35)所述等式，而不以切线外推替代数值反解。

配比受单纯形约束。沿供给域 k 向目标域 j 转移份额，令 $\mathbf{p}(\delta) = \mathbf{p} + \delta(\mathbf{e}_j - \mathbf{e}_k)$ ，则

$$-\frac{dL}{d\delta} = -\frac{\partial L}{\partial h_p} \nabla_{\mathbf{p}} h_p(\mathbf{p}(\delta))^T (\mathbf{e}_j - \mathbf{e}_k). \quad (40)$$

因此配比边际效果必须指明目标域、供给域和当前配方；脱离扣减路径的“单独增加一个领域”并非可行扰动。若要判断两领域互补，需要在候选函数中显式加入交互项，并以独立留出配方检验其增量预测价值。

八、 问题三模型的建立与求解

本章将计算资源配置写成带总算力预算与变量边界的约束优化问题。拉格朗日乘子可解释为预算约束的局部影子价格；对光滑内部解，一阶条件要求各决策方向的边际 Loss 改善与边际算力成本相匹配。若参数、数据或质量变量触及边界，则由 KKT 互补条件刻画约束与最优点的关系。由于成本函数和目标函数不必处处凸，KKT 条件本身不能证明全局最优，因此还需结合边界状态、数值核验及不同预算情景解释解的适用范围。不同成本函数和上下文长度改变边际成本曲线，因此可能引起最优资源组合的结构性转换。

8.1 预算约束下的联合配置模型

问题二主模型在本章写成 $B_{\text{eff}} = Be^{\gamma Q_0}$ 、 $\rho_D = \gamma$ 的等价形式。具体参数为

$$(E, A, B_{\text{eff}}, \alpha, \beta, \rho_D) = (0.909046, 0.540173, 2.103696, 0.279054, 0.099598, 0.317893), \quad (41)$$

且 $\rho_N = E_1 = 0$ 。配比情景采用式(33)的 Form A，并以正式接口给出的 h_p 与 λ_p 表示；主预算网格固定 $\lambda_p = 0$ ，配比响应另作离散候选敏感性。

令 N, D 为实际参数数与 token 数， ℓ 为上下文长度。基础训练项采用常用近似 $6ND^{[6]}$ ，与注意力和质量处理成本共同写为

$$C_{\text{use}} = 6ND + \eta ND\ell + D[g(Q) - g(Q_0)]_+ \leq C, \quad (42)$$

其中 $\eta \in \{10^{-4}, 2 \times 10^{-4}, 4 \times 10^{-4}\}$ ， $\ell \in \{2048, 4096, 8192, 32768, 131072\}$ 。质量成本比较三种预设形式：

$$g_{\text{exp}}(Q) = 10^7 e^{6Q}, \quad g_{\text{pow}}(Q) = 5 \times 10^9 Q^4, \quad g_{\text{log}}(Q) = 2 \times 10^9 \log(1 + 10Q). \quad (43)$$

三类函数与三档 η 共同构成结构敏感性情景。优化盒与 B6 支持范围一致： $0.07 \leq N/10^9 \leq 11.97$ 、 $10 \leq D/10^9 \leq 600$ 、 $0.5 \leq Q \leq 1$ 。高预算处的闲置算力对应支持盒上界被激活。

8.2 预算档位下的配置结果

三档 η 、五档上下文、三种质量成本与三档预算构成 135 个情景，其中 123 个可行、12 个不可行。默认 $\eta = 2 \times 10^{-4}$ 的 45 个主情景中 42 个可行、3 个不可行。表 24 给出指数成本、 $\ell = 32768$ 的代表解。

表 24 最新版指数质量成本、 $\ell = 32768$ 、 $\eta = 2 \times 10^{-4}$ 的条件最优配置

预算 FLOPs	N (B)	D (B)	Q_B	Loss	闲置率	状态
10^{19}	0.07695	10.000	0.52607	3.42899	0.00%	D 下界
10^{22}	6.29402	120.706	1.00000	2.18204	0.00%	Q 上界
10^{24}	11.97000	600.000	1.00000	1.98876	90.75%	盒上界

中预算时， N, D 仍为内部解而 Q 达上界；高预算时三项均到支持盒上界。图 10 展示两种上下文长度下的 Loss 曲线，图 11 展示 $\ell = 32768$ 时 N, D, Q 的分配路径。




图 10 最新版 45 个主情景中两种上下文长度的最小预测 Loss




图 11 $\ell = 32768$ 时三种质量成本下的资源配置路径

8.2.1 活动约束与主导成本区间

只给出若干最优点会掩盖约束何时切换。图 12 读取默认 $\eta = 2 \times 10^{-4}$ 的全部 45 个主情景，以三种质量成本为分面，并按预算和上下文标出不可行、基础训练主导与注意力主导。三种质量成本给出相同的主导成本分区： $\ell \leq 8192$ 时基础训练项较大， $\ell \geq 32768$ 时注意力项较大；当 $C = 10^{19}$ 且 $\ell = 131072$ 时，三种成本均无法满足盒内最小 N, D, Q 的预算要求，形成 3 个不可行情景。

预算档位决定的是另一类状态变化。低预算的 12 个可行情景中， D 全部固定在 10B 下界， N 均为内部解，8 个情景保持参考质量、4 个情景选择内部质量；中预算 15 个情景的 N, D 均为内部解而 Q 全部到达上界；高预算 15 个情景则 N, D, Q 全部到达支持盒上界。高预算闲置率的中位数为 94.28%，最大值为 95.32%。因此“预算增加但 Loss 不再明显下降”首先是盒约束截断，而不是经验规律证明真实系统已经没有可用扩展方向。

为明确识别结构性转移，对每个固定的 (η, ℓ, g) 情景记录最优点的活动状态向量

$$\mathbf{s}(C) = (s_N, s_D, s_Q, s_{\text{idle}}),$$

其中前三项分别标记 N, D, Q 处于下界、内部或上界（ Q 的下界记为参考质量 Q_0 ）， s_{idle} 标记预算是否因支持盒上界而未用尽；判定边界时采用求解器数值容差。沿 $10^{19} \rightarrow 10^{22} \rightarrow 10^{24}$ FLOPs 比较该向量，若其离散状态发生变化，即记为预算诱发的结构性转移，而不以连续指标的小幅波动代替策略变化。重跑结果显示低预算主要受 D 下界约束，中预算转为质量上界约束，高预算则 N, D, Q 同时到达支持上界并出现显著闲置；




图 12 默认 η 下 45 个主情景的可行性与主导成本状态

这给出了由“数据量受限”到“质量饱和”再到“支持盒饱和”的可复核转移路径。该识别只对给定成本函数、 η 、上下文候选与标度律支持盒成立。

表 25 默认 η 下各预算档的可行数与边界状态

预算	可行/总数	N 状态	D 状态	Q 状态	闲置率中位数
10^{19}	12/15	12 内部	12 下界	8 参考、4 内部	0.00%
10^{22}	15/15	15 内部	15 内部	15 上界	0.00%
10^{24}	15/15	15 上界	15 上界	15 上界	94.28%

8.3 上下文长度下的不确定性传播

由式(42)可得 $C_{\text{attn}}/C_{\text{train}} = \eta\ell/6$ 。默认 η 下，五个候选长度对应的比值为 0.0683、0.1365、0.2731、1.0923、4.3691；它与预算无关，却完全依赖未校准的 η 。长上下文在本成本式中占用更多预算，目标函数没有额外识别其能力收益。

题目要求的注意力与基础训练开销相当时满足 $\eta ND\ell_{\text{crit}} = 6ND$ ，故

$$\ell_{\text{crit}} = \frac{6}{\eta}. \quad (44)$$

三档 $\eta = (10^{-4}, 2 \times 10^{-4}, 4 \times 10^{-4})$ 对应的临界长度分别为 60000、30000、15000 token。按 C7 支持范围选取的五个外生候选长度 2048、4096、8192、32768、131072 均纳入情景网格；在默认 η 下，临界点位于 8192 与 32768 之间。完整敏感性分析交叉比较三档 η 、五档长度、三种质量成本及三档预算（共 135 个情景），而不是把 ℓ 当作内点变量优化。随着 η 增大，临界点左移；例如 $\eta = 4 \times 10^{-4}$ 时 $\ell_{\text{crit}} = 15000$ ，故 32768 token 已处于注意力成本高于基础训练成本的区间。C7 提供的是可行长度支持，不负责校准成本系数 η ；因此跨 η 的变化应解释为情景敏感性，而非估计出的真实系统参数。

三类质量成本函数的比较也改变最优资源分配，而不仅改变总成本数值：默认 η 的低预算可行解中，8 个保持 $Q = Q_0$ 、4 个选择内部质量，表明是否投入质量依赖成本形式；中预算 15 个情景的 Q 均到达上界，但 N, D 的内部配置随成本形式变化；高预算下三类决策均到达支持上界，额外预算因而主要表现为闲置。上述结论对应既定的三类 $g(Q)$ 与参数取值，不能外推为成本函数的经验估计。




图 13 上下文长度与注意力/基础训练成本比

问题一 LightGBM 文件接口共提供 1214 个配方，加入参考点 p_0 后有 1215 个离散候选；这一候选设计与 RegMix 的配比回归框架一致^[4]，且 $h_{\text{agg}} \in [0, 0.333013]$ 。当前 LightGBM 响应文件下， p_0 是这些离散候选中的最小值； λ_p 取 0, 0.5, 1, 1.5 四档进行比较。该优化只检验文件给定响应和参数情景下的数学结果，不构成质量映射或跨附件联合效应的经验验收。

问题二的 60 份组 bootstrap 参数全部成功传播到代表情景。在 $C = 10^{22}$ 、 $\ell = 32768$ 、默认 η 与指数成本下， N, D, L 的 bootstrap 中位数为 6.354、119.617、2.18091；95% 分位范围分别为 [4.920, 8.363]、[91.904, 152.464]、[2.16731, 2.19881]。这些范围只覆盖 B6 组抽样变化，不覆盖质量成本、 η 、 λ_p 或跨机制误差。

图 14 展示 60 次传播的完整经验分布。 N 与 D 的分布宽度明显大于最优 Loss 的宽度：不同参数组合可以落在相近的 Loss 等高线上，所以“预测性能较稳定”并不意味着“资源配比唯一”。60 次中 Q 均为 1，故不绘制一个退化的质量直方图；这一现象说明代表点已经受质量上界约束，而不是说明质量参数没有不确定性。若改变质量成本形式或放宽支持盒， Q 的最优状态可能随之改变。




图 14 代表情景中 60 次组重抽样传播的 N, D, L 分布

从决策角度看，重抽样区间应按层次使用： $L \in [2.16731, 2.19881]$ 描述 B6 组抽样在冻结成本模型下的输出变化； N, D 区间描述相同传播下的可替代资源组合；三种成本、三档 η 和四档 λ_p 之间的差异则属于结构敏感性。将两者混成单一“置信区间”会遗漏成本设定这一更上层的不确定性。

9 个局部/KKT 检查全部通过，最大相对改进仅 6.61×10^{-11} ，最小预算余量为 $-1.51 \times$

10^{-13} (数值舍入量级)。在 $C = 10^{22}$ 、 $\ell = 32768$ 的代表工作点，总最优 Loss 的有限差分预算弹性为

$$\epsilon_C = \frac{d \log L^*}{d \log C} = -0.04334897, \quad (45)$$

该值作为问题四机制腿的最新版跨问输入。

8.3.1 成本约束与 KKT 最优性核验

在预算式 $C_{\text{use}} = D\{K(\ell)N + \Psi(Q)\}$ 的可微内部，三个决策变量对应的成本导数为

$$C_N = KD, \quad C_D = KN + \Psi(Q), \quad C_Q = Dg'(Q) \quad (Q > Q_0). \quad (46)$$

若预算约束激活且三个变量均不在盒边界，设拉格朗日乘子为 $\mu \geq 0$ ，内点条件为

$$L_N + \mu C_N = 0, \quad L_D + \mu C_D = 0, \quad L_Q + \mu C_Q = 0, \quad C_{\text{use}} = C. \quad (47)$$

前两式给出参数量与数据量的单位算力边际 Loss 平衡，第三式连接质量改善的边际收益与质量成本。变量触及上下界时，改用相应的互补条件； $Q = Q_0$ 处的正部函数 $[g(Q) - g(Q_0)]_+$ 使用单侧比较。数值程序依次检查最低成本可行性、内点、各面边界与盒顶点。

9 个局部/KKT 实例全部通过，最大相对改进为 6.61×10^{-11} ，最小预算余量为 -1.51×10^{-13} ，均处于数值舍入量级。在当前成本式中 $C_p \equiv 0$ ，因此配比候选可与连续的 N, D, Q 子问题分开求解。

九、 问题四模型的建立与求解

Benchmark 得分是有界比例指标。本问在潜在预测量 $\eta_i(t)$ 上建立规模与时间动态项，再通过 $S_i(t) = 100\sigma(\eta_i(t))$ 映射回百分制范围；参数按评分尺度上的加权平方误差拟合，并非先对观测分数作 **logit** 变换后进行线性回归。预训练与对话/微调模型分轨估计，允许不同阶段具有不同基线和演化路径；时间项仍是观测性条件趋势，不能单凭函数形式解释为技术进步的因果效应。分位前沿描述样本分布的高端位置，也不等同于单个模型的期望得分。

9.1 固定版本主样本的筛选口径

问题四要求区分模型规模扩张与非规模技术进步，并在明确评测口径下考察未来能力前沿。为避免把排行榜上的异质结果直接当作同口径时间序列，本研究联合开放权重候选、固定版本记录、C8 评测 JSON、任务配置及评测代码。开放权重筛选按修订方案的 $O = W \cap V \cap \mathcal{E} \cap T$ 规则执行：候选须具有开放权重、可锁定的精确版本、可追溯的评测记录以及可核验的任务协议。424 个权重候选归并为 420 个不同名称；54 个候选具有与官方修订记录相连的 SHA 证据，最终主样本 O 为 34 个固定版本，其中 pretrained 14 个、chat/finetuned 20 个，覆盖 15 个发布方。另保留 182 个版本时间可用但不满足 O 全部条件的辅助记录，不混入主样本。

主时间变量使用固定修订版本的首个制品日期；C2 能力快照日为 2025-03-13。提交日期、发布日期与制品日期分别保留，不相互替代。许可核查中，主样本有 19 个 Apache-2.0、7 个 MIT（遵循各自附加条件）及 8 个未知；按严格 R/R+ 证据链确认的对象数为 0，表示尚未完成权重、版本、评测 JSON、评分器及运行配置的闭环核验，而不表示这些模型不存在。

C8 共发现 1,958 个物理 JSON 文件，分布于 1,863 个目录。按每目录文件名最早的 JSON 固定选档后，得到 1,860 份有效记录和 3 份选中但无效记录；另有 1 份损坏文件未入选，因为同目录存在更早的有效文件。跨 C2 与任务结果匹配得到 58 组运行记录，其中 54 组另有官方 C2 SHA 关联。审计还识别出 4 种任务配置指纹和 6 个评测代码哈希，因此即使进入主样本，也不将所有运行宣称为完全相同的协议。

能力度量采用 IFEval、BBH、MATH、GPQA、MUSR、MMLU-Pro 六项任务的等权宏平均；前沿预测以任务内季度第 90 百分位描述高端表现。各任务分数先按统一规则转换到百分制，再聚合。图 15 展示六项任务的季度轨迹，轨迹并不同步，说明宏平均是可复算的综合指标，但不能消除任务难度、评分器和协议差异。

9.2 有界能力动态模型的留组验证

在主样本上比较三种预先界定的候选：辅助样本动态模型、主样本动态模型和主样本规模模型，并以常数预测为基线。候选模型通过 **sigmoid** 映射约束预测分数在百分制范围内；验证分别按发布方、家族代理组和近期版本组留出，以检查模型对不同外推对象的敏感性。外层 MAE 汇总如下。

基于训练折内部的归一化最坏误差构造稳健平均时，候选权重为 0.49、0.06、0.45；该平均在留发布方上的 MAE 为 8.8694，较该切分下最佳单模型 6.3153 高 40.44%，且最大权重的四分位距为 0.5425。依照预先约定的回退规则，不把不稳定的平均模型作为最终点预测器，而回退到主样本动态候选。图 16 汇总外层验证与回退诊断。回退只确定后续条件计算所用的候选，不代表主样本动态模型已通过所有外部有效性检验。




图 15 C8 六项任务的分季度能力分布与前沿轨迹

表 26 版本统一候选模型的外层留组验证 MAE

候选模型	留发布方	留家族代理组	留近期版本组
辅助样本动态	6.3153	5.6672	7.5008
主样本动态	9.0710	6.2869	7.2286
主样本规模	8.7137	6.0105	7.2872
常数基线	8.7973	9.2398	9.3250

9.3 增长来源的条件归因

修订方案将规模扩张与非规模变化分开核算。对同一版本时间口径下的观测差异，采用如下记账式：

$$\Delta S_{\text{obs}} = \Delta S_N + \Delta S_t + \Delta S_{\text{mix}}, \quad (48)$$

其中 ΔS_N 是规模项， ΔS_t 是时间项， ΔS_{mix} 汇集模型组成、后训练、数据、评测协议及模型未解释部分。当前对齐样本给出的点分解分别为 0.879572、2.302270 和 7.304008 分，观察差为 10.485849 分。该式是依赖样本和模型规格的条件归因账目，不是随机干预意义下的因果效应，也不能将最后一项直接命名为纯算法进步。

在仅保留“规模+时间”两项的条件子模型中，两项的相对份额为 27.64% 和 72.36%；它们只描述该子模型解释部分的内部拆分，不是行业整体贡献比例。跨 27 个合法规格




图 16 候选模型的外层留组误差与稳健平均回退诊断

的规模贡献敏感性范围为 11.10%–97.55%，进一步表明分解依赖时间轴、样本与控制项设定。图 17 给出基准分解及规格敏感性。




图 17 规模与时间的条件贡献分解及规格敏感性

为补充说明机制，本研究还做了两个边界明确的局部分析。其一，Qwen2 与 Qwen2.5 家族内的 2×2 比较，将各自两因素增益拆为规模与后训练项；对应规模项占家族内两因素增益的 82.15% 和 79.32%。但只有 3/8 个精确版本 ID 与本地 JSON 完全一致，因此该数值仅为家族局部描述，不能推广为行业因果份额。其二，RegMix 在 64 个配比身份、13 项任务及 128 个端点观测上估计配比—能力局部响应；联合模型分组交叉验证 MAE 为 0.179063，略低于加性基线 0.181349。该实验反映给定任务和混合身份下的局部情景，不提供行业日历增长率。

9.4 分轨能力前沿情景预测

远期情景以 2025-03-13 为锚点，在固定模板上分别计算 pretrained 与 chat/finetuned 两条轨道。输入采用制品时间动态、主样本动态候选及资源增长情景，并按修订方案规定的计算资源增速衰减设定生成条件值。每条轨道在其对应的固定版本集合上计算，两条轨道合计 34 个固定版本（pretrained 14 个、chat/finetuned 20 个）；新增家族冲击另行列示，不并入固定模板的平均分。所选情景的结果为：pretrained 轨道 12/24 个月为 37.3107/41.2719 分，chat/finetuned 轨道为 38.5715/42.5756 分。

表 27 固定模板分轨前沿的条件预测及规格包络

轨道与期限	条件点值	规格下界	规格上界
Pretrained, 12 个月	37.3107	33.314	42.096
Pretrained, 24 个月	41.2719	33.962	51.133
Chat/finetuned, 12 个月	38.5715	34.515	43.407
Chat/finetuned, 24 个月	42.5756	35.173	52.470

表中包络是 27 种预设合法规格下的情景范围，不是具有已校准覆盖率的置信区间或预测区间。长周期前瞻数据不足，历史回测最长仅覆盖 1–3 个月组合，故不能声称 12/24 个月预测已经验证，也不报告行业总体增长点估计。图 18 呈现固定模板情景及不确定性来源。




图 18 固定版本分轨的条件前沿、规格敏感性与新增家族情景

9.4.1 有界分数映射与预测情景范围

为使预测分数保持在百分制内，令线性预测量 $\eta_i(h)$ 经 sigmoid 函数映射：

$$S_i(h) = 100 \sigma(\eta_i(h)), \quad \sigma(x) = \frac{1}{1 + e^{-x}}, \quad \text{logit}(u) = \log \frac{u}{1 - u}. \quad (49)$$

固定模板的 12/24 个月计算是在既定制品时间、资源增长和模型规格下推进 η_i ，再对轨道内模板汇总。由于原始分数由有界变换得到，模板平均分、任务宏平均和季度前沿分位数是不同统计对象；本章不将其中任一种直接等同为所有模型均可达到的行业上限。

规格包络由 27 组预先定义且满足约束的模型与资源设定逐一计算，再对同一轨道、同一期限取最小值和最大值。它表达设定变化导致的结果跨度，并未通过长期前瞻样本校准覆盖率；因此不能标注为 95% 置信区间，也不能与短期回测残差区间混为一谈。

规模与时间的分解可写为 $\Delta S_{\text{obs}} = \Delta S_N + \Delta S_t + \Delta S_{\text{mix}}$ 。其中前两项依赖所选回归规格和比较窗口，剩余项包含未观测机制及样本构成变化。即使将规模与时间的点估计相除得到相对份额，该比例也只适用于该条件子模型解释的部分；它不具备对行业总体作因果解释所需的干预识别。

最后，Loss-Benchmark 桥接只有在训练体系、版本和评测口径可配对且能通过跨家族验证时，才可作为跨题数值转换。当前 C5 Medium 留家族 MAE 未优于常数基线，

High 层只有单一家族，C6 又与 C5 嵌套，故桥接门槛未通过。相应候选回归式仅用于记录已完成的检验，不用于产生确定的未来能力分数。

9.5 Loss–Benchmark 桥接检验

前三问的训练 Loss 与本问多任务 Benchmark 分数来自不同数据结构，不能直接拼接。交接包按可比性分层检查 C5、C6 与问题三输出：C5 含 43 条记录，其中 High 7 条且全部来自 Pythia，Medium 36 条、覆盖 9 个家族；C6 共 75 条，包含全部 C5 记录并增加 32 条 Medium 记录，因此 C5 与 C6 不是独立验证集。

C5 Medium 的候选仿射式为

$$\widehat{LB}_{\text{avg}} = 48.92927 - 14.52873L. \quad (50)$$

其样本内 $R^2 = 0.2398$ ，留一模型家族 MAE 为 8.0583，略差于常数基线 7.9996（技能分数为 -0.7% ），因此未通过跨家族桥接检验。C5 High 虽可拟合候选式，但仅有一个家族，无法进行留家族验证；C6 Medium 的误差改善由于样本与 C5 嵌套，不能视作独立确认。图 19 汇总分层样本与诊断结果。




图 19 Loss–Benchmark 桥接的样本可比性与留家族诊断

问题三到 C5 的局部候选映射使用 7 个 Pythia 锚点，留一误差虽低于常数基线，但只有单一家族，不能向外推广。另一个固定质量 $Q = 0.5$ 的 Q2-to-C5 对照在 7 个 High 记录上的平均绝对差为 0.1610，且 5/7 的预测高于观测并超出 SET_A 范围；这只能否定该设定下“数值直接相等”，并不能证明某个仿射变换成立。因缺少同版本配对观测，Q2/Q3 到 C5/C6 的正式桥接仍未通过，本章不将 Loss 转换成确定的 Benchmark 分数。

十、 模型评价与总体结论

10.1 分层验证设计

问题一先审计再评分，配比预测器经同尺度留出、跨规模排序与整簇留出检验。问题二报告 B1 拟合、B6 组交叉验证、B7-new 留出与 B8 方向压力测试；A 端另提供 M2 候选配比响应文件，其哈希、字段顺序和基准点自检通过，但这不等于正式 Q1→Q2 质量/配比接口验收。问题三使用问题二 MQ 的精确等价参数化，60/60 次组重抽样传播及 9/9 个局部/KKT 核验通过；其中涉及 $Q_A \rightarrow Q_B$ 与配比迁移的部分仍是条件情景。问题四完整重跑 20/20 个脚本，并明确区分七项不受跨题接口影响的 C-only 结果与随机制腿更新的预测结果。

10.2 模型的稳健性验证

四问的“验证”含义并不相同。问题一的 1M 留出检验隔离了训练配方记录，整簇留出进一步隔离配方结构；问题二的 B7-new 只隔离新质量水平，并没有隔离新的 (N, D) 网格；问题三的 KKT 检验验证数值最优性，却不验证成本函数符合现实；问题四的 1–3 月滚动回测验证短期协议，不能转化为 24 月覆盖率。表 28 把这些差异集中列出。

表 28 四问模型的主要验收量、稳健性检查与可推广范围

问题	主验收量	额外稳健性检查	当前可支持的范围
一	1M 留出 NRMSE 0.1309	整簇 0.2391；跨规模排序；方向与置换	冻结 17 域配比支持附近的 Loss 预测
二	B6/B7-new 含质量 RMSE 0.07609/0.04909	B2–B5 跨来源；B8 150/150 方向冲突	B6/B7 半合成机制附近的条件质量响应
三	123/135 情景可行	60/60 重抽样；9/9 KKT；三类成本与三档 η	支持盒和给定成本式内的条件资源解
四	34 个固定版本主样本；C8 有效 1,860 条	三类候选留组验证、27 种情景规格、C5/C6 留家族桥接	2025-03-13 锚点下的两轨条件情景；长期覆盖与桥接仍未验收

模型的可解释性主要来自显式分解，而不是把所有关系压入一个黑箱。问题一把综合质量拆为三个语义组，并保留 22 项组内权重；问题二把不可约项、参数项、数据项和质量指数项分开；问题三把训练、注意力和质量处理成本分别核算，并报告每个边界状态；问题四把机制、近期和长历史三条增长证据分腿组合。

10.3 跨问题的误差传递

跨问链的可靠性由最弱的关键接口限制，而不是由单个环节的最高拟合优度决定。M2 候选配比文件的内部自检通过，但正式 Q1→Q2 质量/配比接口及完整联合模型尚未端到端验收；B 端没有配比列， $Q_A \rightarrow Q_B$ 映射与 λ_p 因而仍未识别，只能作为情景参数。问题二到问题三的参数化转换误差为 0，只证明公式转换正确，不能消除 B8 的方向冲突；问题三到问题四的机制弹性已经更新，但 Loss–能力桥接只有 75 行、高可比记录 7 行、 $R^2 = 0.2774$ 。

由此，全文结果按证据强度分三层报告：直接或同源留出的结果（问题一 1M 留出、B1 同源轨迹、C1/C8 清洗统计）可直接引用；受生成机制约束的半合成或情景结果（B6–B8、问题三成本网格）需附结构敏感性；跨来源预测（问题四 12/24 月能力情景）则须与反向证据并列。后两类不能只保留最有利的点值。

10.4 资源配置结果的应用条件

若把上述结果用于下一轮真实实验设计，优先级应是补足识别条件，而不是继续扩大无约束外推。最直接的一项是在同一训练体系内共同记录 $(N, D, Q, \mathbf{p}, L)$ ，覆盖 A16 的可靠映射域与 B6 的质量范围，从而估计而非假设 $Q_A \rightarrow Q_B$ 与 λ_p 。质量处理与长上下文成本也需实测，以替换问题三三类预设情景函数，并在盒边界附近补充训练点，用于区分真实饱和与支持域截断。此外还应冻结评测版本与预测协议，持续积累 12–24 个月的同口径前瞻数据，才能检验问题四的远期区间。

就应用而言，这些结果既能帮助筛选值得开展真实训练验证的配方、规模与上下文组合，也能指出结论对方向、成本与权重最敏感的环节。

10.5 模型局限性

第一，问题一的若干指标方向仍属于建模假设，熵权与冗余修正刻画的是评分信号的分布结构，不是指标对训练收益的因果贡献。A16 只有六个 direct/near-direct 可靠映射域，质量代理由配比派生；当前置换与留出结果也未显示稳定的独立预测增益。LightGBM 的单域和双域响应是冻结预测器在指定扣减路径上的有限差分，不能由此认定固有协同、训练因果效应或连续单纯形上的全局最优配比。A12–A15 的 10B/70B Loss 来自既有估算表，只能用于一致性比较。

第二，M2 候选配比文件虽通过内部数值自检，正式 $Q_1 \rightarrow Q_2$ 质量/配比接口仍未通过端到端验收。 Q_A 与 Q_B 没有配对观测，A、B 附件也缺少共同的 $(N, D, Q_B, \mathbf{p}, L)$ 样本，因此 $Q_A \rightarrow Q_B$ 、 λ_p 与 Form A/B 未由联合实验识别。B6/B7/B8 均为半合成，且 B8 的 150 个固定组全部给出与 B6/B7 相反的数值方向；问题二的质量响应只在相应生成机制与校准范围内成立。

第三，问题三的质量成本、 η 和 λ_p 都是情景量，优化结果依赖预设成本式、离散候选集和支持盒；盒上界解是这些条件下的数学最优，而不是现实部署的无约束全局最优。

第四，问题四的条件分解剩余项混合样本组成、后训练、数据、评测协议及模型未解释变化，不能解释为单一因果“技术进步”。C5 Medium 桥接留家族 MAE 为 8.0583，略差于常数基线 7.9996；High 层仅含一个家族，不能进行留家族验证。C8 版本与协议核验显示，长周期情景仍缺少同口径前瞻覆盖率校准；严格开放模型 R/R+ 已确认数为 0 表示取证链未闭环，而非对象不存在。

10.6 总体结论

当前评分规则下，17 域配比模型在问题一留出检验中具有预测力，但领域质量映射没有稳定的独立预测增益。问题二中，B6 组交叉验证的无质量/含质量 RMSE 为 0.12876/0.07609，B7-new 为 0.05896/0.04909；B8 反向关系限制了质量响应的跨机制推广。

问题三最新版的 135 个情景中 123 个可行，默认 η 下为 42/45； $C = 10^{22}$ ， $\ell = 32768$ 代表点的总 Loss 预算弹性为 -0.04335 。问题四按固定版本给出 pretrained 与 chat/finetuned 两条 12/24 月条件情景，点值分别为 37.3107/41.2719 与 38.5715/42.5756；27 种规格包络不是经长期前瞻数据校准的置信区间。规模/时间拆分属于条件归因，Loss–Benchmark 桥接未通过跨家族检验，因此不作行业因果份额或确定分数转换。

四问由此形成一条可复核但有条件的链：质量与配比预测 $\rightarrow$ 半合成质量标度律 $\rightarrow$ 假设成本下的盒内资源配置 $\rightarrow$ 带弱桥接和结构敏感性的能力前沿情景。任何真实训练决策仍需同一实验中的 $(N, D, Q, \boldsymbol{p}, L)$ 联合数据、质量与长上下文成本校准，以及同版本的长期能力评测。

参考文献

- [1] Hwang C-L, Yoon K., *Multiple Attribute Decision Making: Methods and Applications: A State-of-the-Art Survey*, Berlin, Heidelberg: Springer, 128–140, 1981。
- [2] Hoerl A E, Kennard R W., Ridge Regression: Biased Estimation for Nonorthogonal Problems, *Technometrics*, 12(1): 55–67, 1970。
- [3] Ke G, Meng Q, Finley T, et al., LightGBM: A Highly Efficient Gradient Boosting Decision Tree, *Advances in Neural Information Processing Systems*, 30, 2017。
- [4] Liu Q, Zheng X, Muennighoff N, et al., RegMix: Data Mixture as Regression for Language Model Pre-Training, *International Conference on Learning Representations*, 2025。
- [5] Kaplan J, McCandlish S, Henighan T, et al., Scaling Laws for Neural Language Models, <https://arxiv.org/abs/2001.08361>, 访问时间 (2026 年 9 月 27 日)。
- [6] Hoffmann J, Borgeaud S, Mensch A, et al., Training Compute-Optimal Large Language Models, *Advances in Neural Information Processing Systems*, 35, 2022。
- [7] Biderman S, Schoelkopf H, Anthony Q G, et al., Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling, *Proceedings of Machine Learning Research*, 202: 2397–2430, 2023。

AI 使用声明

本文撰写过程中使用生成式人工智能工具 OpenAI Codex，辅助整理题目、团队既有融合方案、实验报告与参考资料，核对已有结果的引用口径，并处理 $\text{\LaTeX}$ 排版与编译问题。所用模型为 GPT-6 sol，开发机构为 OpenAI，模型版本发布日期为 2026 年 9 月 3 日。此外还使用 DeepSeek 的 deepseek v4.1-flash 模型辅助同类整理与核对工作，开发机构为深度求索（DeepSeek），模型版本发布日期为 2026 年 9 月 10 日。文中数值、图表和模型版本以仓库中的原始附件、结构化实验结果及复现记录为依据；AI 输出不作为学术证据，也未用于生成或补齐观测数据。

附件 A 数据附件使用表

附件	实际规模	数据性质	使用方式
A1	51,230 条	质量信号抽样	指标审计、综合质量评分及冲突分析
A2	17,523 条	arxiv 扩展质量信号	去重分析、同域评分对照
A3	203,752 条	github 扩展质量信号	去重分析、同域评分对照
A4/A5	512 组	1M 配比与验证 Loss	配比模型训练及内部模型选择
A6/A7	256 组	1M 配比与验证 Loss	同尺度冻结留出检验
A8/A9	256 组	60M 配比与验证 Loss	跨规模留出及配方排序检验
A10/A11	64 组	1B 配比与验证 Loss	跨规模留出及配方排序检验
A12–A15	各 63 组	配方子集与既有 Loss 估算	10B/70B 一致性参考，不作独立真实实验
A16	17 个领域映射	跨体系参考映射	映射置信类别、质量覆盖率和代理分析
B1	1,176 个检查点	同源训练轨迹	经典及质量扩展标度律拟合
B2	1,029 行	半合成跨来源数据	拟合趋势与外部范围诊断
B3	4,000 行	插值轨迹	同源插值一致性检查
B4/B5	57/44 行	跨族及文献数据	标度律外部排序与敏感性检验
B6	360 行	半合成质量网格	质量模型拟合与组级交叉验证
B7	450 行	半合成扩展网格	扣除重合记录后检验新质量水平
B8	1,704 行	半合成及外推数据	质量–Loss 方向压力测试
B9/B10	B10 为 128 行	大模型元数据与估算 Loss	大模型估算一致性参考
B11/B12	元数据/检查点记录	模型家族及训练信息	跨家族分组、时间与训练轨迹核对
C1	4,576 行	排行榜记录	能力指标、候选集与历史观测审计
C2	版本与任务记录	官方评分快照及 SHA 关联	固定版本主样本的任务分数与版本核验
C3/C4	见审计元数据	历史序列及模型/资源信息	长期时间趋势和资源增长情景
C5	43 行	可比性分层的 Loss–Benchmark 记录	主桥接拟合及留家族检验
C6	75 行	含 C5 的嵌套扩展桥接数据	Medium 层敏感性分析，不作独立验证
C7	五个选用长度	架构上下文信息	问题三上下文预算情景
C8	1,958 份物理 JSON/1,863 个目录	逐任务评测结果	六任务分数、季度前沿与版本/协议审计

附件 B Python 核心代码

B.1 问题一：质量评分与配比验证

综合质量权重实现：src/q1_revision_v2_1/quality.py

```
1  """ 固定三语义组：组间等权，组内熵信息差异与组内 Spearman 冗余。 """
2  import json
3  import lzma
4
5  import numpy as np
6  import pandas as pd
7
8  from q1.audit.inventory import expected_files
9  from q1_revision_v2.quality import scalarize, entropy_weights
10 from .common import paths, save_json
11
12
13 def validate_groups(fields, groups):
14     members = [field for names in groups.values() for field in names]
15     if len(groups) != 3 or len(members) != 22 or len(set(members)) != 22 or set(members) != set(fields):
16         raise ValueError(" 三个固定语义组必须恰好覆盖 22 个字段且无重叠")
17
18
19 def group_weights(z_reference, rho, fields, groups, excluded=()):
20     """ 每组单独算熵差异及组内绝对 Spearman 冗余；退化组记录 fallback。 """
21     excluded = set(excluded)
22     global_weight = np.zeros(len(fields), dtype=float)
23     rows, fallback = [], []
24     score_indices = {}
25     for group, names in groups.items():
26         indices = np.array([fields.index(name) for name in names if name not in excluded], dtype=int)
27         if not len(indices):
28             raise RuntimeError(f"{group} 排除后无指标")
29         block = z_reference[:, indices]
30         variable = np.ptp(block, axis=0) > 1e-12
31         if not variable.any():
32             raise RuntimeError(f"{group} 无非退化有效指标，无法执行确定性 fallback")
33         try:
34             d, _ = entropy_weights(block)
35         except RuntimeError:
36             d = np.zeros(len(indices))
37         subset_rho = rho[np.ix_(indices, indices)]
38         if len(indices) > 1:
39             redundancy = (np.abs(subset_rho).sum(axis=1) - 1) / (len(indices) - 1)
40         else:
41             redundancy = np.zeros(len(indices))
42         nonredundancy = np.clip(1 - redundancy, 0, 1)
43         information = d * nonredundancy
44         if information.sum() <= 1e-15:
45             within = variable.astype(float) / variable.sum()
46             fallback.append({"group": group, "reason": "all_entropy_redundancy_product_zero",
47                             "valid_nonconstant_count": int(variable.sum()), "policy": "equal_nonconstant"})
48     else:
```

```

49         within = information / information.sum()
50         global_weight[indices] = within / len(groups)
51         score_indices[group] = indices
52         for local, index in enumerate(indices):
53             rows.append({"field": fields[index], "group": group, "entropy": d[local],
54                         "redundancy": redundancy[local], "nonredundancy": nonredundancy[local],
55                         "within_group_weight": within[local],
56                         "global_weight": global_weight[index], "nondegenerate": bool(variable[local])})
57         if not np.isclose(global_weight.sum(), 1, atol=1e-10) or np.any(global_weight < -1e-12):
58             raise RuntimeError(" 层级权重非负或归一化约束失败")
59         return global_weight, pd.DataFrame(rows), fallback, score_indices
60
61
62 def reconstruct_matrix(root, out, old, config, old_config):
63     fields = old_config["quality_fields"]
64     accepted = pd.read_csv(old / "audit/source_ledger.csv.gz", usecols=["attachment", "line_number",
65     ↪ "record_id", "domain", "status"], keep_default_na=False)
66     accepted = accepted[accepted.status.isin(("valid", "duplicate_exact"))]
67     lookup = {(r.attachment, int(r.line_number)): (r.record_id, r.domain, r.status)}
68     for r in accepted.itertuples():
69         values, qparts, identifiers = [], [], []
70         files = expected_files(root)
71         qindex = fields.index("qurater")
72         for attachment in ("A1", "A2", "A3"):
73             with lzma.open(files[attachment][0], "rb") as stream:
74                 for line, raw in enumerate(stream, 1):
75                     entry = lookup.get((attachment, line))
76                     if entry is None:
77                         continue
78                     record = json.loads(raw)
79                     if record["id"] != entry[0]:
80                         raise RuntimeError(" 评分输入 ID 与审计账本不一致")
81                     scalar = scalarize(record, old_config)
82                     qparts.append(scalar[qindex])
83                     scalar[qindex] = np.nan
84                     values.append(scalar)
85                     identifiers.append((attachment, line, entry[0], entry[1], entry[2]))
86     meta = pd.DataFrame(identifiers, columns=["attachment", "line_number", "record_id", "domain",
87     ↪ "status"])
88     old_scores = pd.read_csv(old / "quality/sample_scores.csv.gz")
89     for col in ("attachment", "line_number", "record_id", "domain", "status"):
90         if not meta[col].equals(old_scores[col]):
91             raise RuntimeError(f"v2.1 与 v2 样本顺序/视图不一致: {col}")
92     raw = np.asarray(values, dtype=float)
93     qr = np.asarray(qparts, dtype=float)
94     union = (meta.status == "valid").to_numpy()
95     qlo, qhi = np.quantile(qr[union], old_config["winsor_quantiles"], axis=0)
96     qr_normalized = np.divide(np.clip(qr, qlo, qhi) - qlo, qhi - qlo,
97     ↪ out=np.zeros_like(qr), where=qhi > qlo)
98     raw[:, qindex] = qr_normalized.mean(axis=1)
99     lo, hi = np.quantile(raw[union], old_config["winsor_quantiles"], axis=0)
100     z = np.divide(np.clip(raw, lo, hi) - lo, hi - lo,
101     ↪ out=np.zeros_like(raw), where=hi > lo)
102     for name in old_config["negative_after_scalarization"]:
103         index = fields.index(name)
104         if hi[index] > lo[index]:

```

```

103     z[:, index] = 1 - z[:, index]
104     stored_z = z.astype(np.float32)
105     old_z = np.load(old / "quality/normalized_22.npy", mmap_mode="r")
106     max_difference = float(np.max(np.abs(stored_z - old_z)))
107     if stored_z.shape != old_z.shape or max_difference > 2e-6 or not np.isfinite(z).all():
108         raise RuntimeError(f"重建 22 维矩阵未通过 v2 一致性核验: max_diff={max_difference}")
109     old_params = pd.read_csv(old / "quality/indicator_parameters.csv")
110     if not np.allclose(lo, old_params.q01) or not np.allclose(hi, old_params.q99):
111         raise RuntimeError("重新拟合 q01/q99 与 v2 固定尺度不一致")
112     np.save(out / "quality/normalized_22.npy", stored_z)
113     pd.DataFrame({"field": fields, "q01": lo, "q99": hi,
114                  "direction": ["negative" if f in old_config["negative_after_scalarization"] else
115                               "direction_provisional" if f in config["direction_provisional"] else "positive"
116                               for f in fields]}).to_csv(out / "quality/normalization_parameters.csv", index=False)
117     return meta, old_scores, z, union, max_difference
118
119
120 def run(root, config, old_config):
121     root, out, old = paths(root)
122     dest = out / "quality"
123     dest.mkdir(parents=True, exist_ok=True)
124     fields = old_config["quality_fields"]
125     validate_groups(fields, config["groups"])
126     meta, old_scores, z, union, max_difference = reconstruct_matrix(root, out, old, config, old_config)
127     ref = np.asarray(z[union], dtype=float)
128     rho = pd.DataFrame(ref, columns=fields).corr(method="spearman").fillna(0).to_numpy(copy=True)
129     np.fill_diagonal(rho, 1)
130     old_rho = pd.read_csv(old / "quality/spearman_signed.csv", index_col=0).to_numpy()
131     if not np.allclose(rho, old_rho, atol=1e-8):
132         raise RuntimeError("重算 Spearman 与 v2 不一致")
133     pd.DataFrame(rho, index=fields, columns=fields).to_csv(dest / "spearman_signed.csv")
134     wmain, weight_rows, fallbacks, indices = group_weights(ref, rho, fields, config["groups"])
135     wdrop, drop_rows, drop_fallbacks, _ = group_weights(ref, rho, fields, config["groups"],
136     ↪ config["direction_provisional"])
137     wequal = np.zeros(len(fields))
138     for group, idx in indices.items():
139         nondegenerate = idx[np.ptp(ref[:, idx], axis=0) > 1e-12]
140         wequal[nondegenerate] = 1 / (len(config["groups"]) * len(nondegenerate))
141     if not np.isclose(wequal.sum(), 1):
142         raise RuntimeError("H-equal-within 权重和不为 1")
143     old_weights = pd.read_csv(old / "quality/indicator_parameters.csv").set_index("field")["w_main"]
144     weight_rows["old_v2_global_weight"] = weight_rows.field.map(old_weights)
145     weight_rows["direction_status"] = weight_rows.field.map(lambda f: "direction_provisional" if f in
146     ↪ config["direction_provisional"] else "fixed")
147     weight_rows.to_csv(dest / "hierarchical_weights.csv", index=False)
148     drop_rows.to_csv(dest / "drop4_weights.csv", index=False)
149     pd.DataFrame(fallbacks + drop_fallbacks, columns=["group", "reason", "valid_nonconstant_count",
150     ↪ "policy"]).to_csv(dest / "weight_fallbacks.csv", index=False)
151     group_scores = {}
152     for group, idx in indices.items():
153         group_scores[group] = np.asarray(z[:, idx]) @ (wmain[idx] * len(config["groups"]))
154     scores = {"Q_hierarchical_balanced": 100 * np.asarray(z) @ wmain,
155             "Q_hierarchical_drop4": 100 * np.asarray(z) @ wdrop,
156             "Q_hierarchical_equal_within": 100 * np.asarray(z) @ wequal}
157     if not np.allclose(scores["Q_hierarchical_equal_within"], old_scores["Q_group_equal"], atol=3e-5):
158         raise RuntimeError("H-equal-within 与 v2 Q_group_equal 不一致")

```

```

156 if any(np.nanmin(a) < -1e-8 or np.nanmax(a) > 100+1e-8 for a in scores.values()):
157     raise RuntimeError("Q 超出 [0,100]")
158 for key, values in group_scores.items():
159     meta["S_" + key] = values
160 for key, values in scores.items():
161     meta[key] = values
162 meta["q_hierarchical_balanced"] = scores["Q_hierarchical_balanced"] / 100
163 for key in ("Q_entropy", "Q_entropy_redundancy", "Q_equal22", "Q_group_equal", "Q_TOPSIS",
    ↪ "Q_direction_drop4"):
164     meta[key] = old_scores[key].to_numpy()
165 meta.to_csv(dest / "sample_quality_scores.csv.gz", index=False, compression={"method": "gzip",
    ↪ "mtime": 0})
166 meta[["attachment", "line_number", "record_id", "domain", "status", *["S_" + g for g in
    ↪ config["groups"]]]].to_csv(dest / "semantic_group_scores.csv.gz", index=False,
    ↪ compression={"method": "gzip", "mtime": 0})
167 rng = np.random.default_rng(config["seed"])
168 score_names = [*scores, "Q_entropy_redundancy", "Q_group_equal", "Q_TOPSIS"]
169 views = [("union_unique", meta[union]), ("A1", meta[meta.attachment == "A1"]),
170         ("A2", meta[meta.attachment == "A2"]), ("A3", meta[meta.attachment == "A3"])]
171 domain_rows, group_distribution = [], []
172 for view, frame in views:
173     for domain, sub in frame.groupby("domain"):
174         row = {"view": view, "domain": domain, "n": len(sub)}
175         matrix = sub[score_names].to_numpy(dtype=float)
176         row.update({key: float(matrix[:, col].mean()) for col, key in enumerate(score_names)})
177         row["Q_hierarchical_balanced_sd"] = float(matrix[:, 0].std(ddof=1)) if len(sub) > 1 else None
178         bootstrap = np.empty((config["bootstrap_repetitions"], 3))
179         for b in range(len(bootstrap)):
180             bootstrap[b] = matrix[rng.integers(0, len(sub), len(sub)), :3].mean(axis=0)
181         for col, key in enumerate(list(scores)):
182             row[key + "_ci025"], row[key + "_ci975"] = np.quantile(bootstrap[:, col], [.025, .975])
183         domain_rows.append(row)
184         for group in config["groups"]:
185             a = sub["S_" + group].to_numpy()
186             group_distribution.append({"view": view, "domain": domain, "group": group, "n": len(a),
187                                     "mean": a.mean(), "sd": a.std(ddof=1) if len(a)>1 else None,
188                                     "q05": np.quantile(a, .05), "median": np.median(a), "q95": np.quantile(a, .95)})
189 domains = pd.DataFrame(domain_rows)
190 domains.to_csv(dest / "domain_quality_summary.csv", index=False)
191 pd.DataFrame(group_distribution).to_csv(dest / "semantic_group_distribution.csv", index=False)
192 reference = meta[union]
193 stability = []
194 for method in score_names:
195     row = {"method": method, "spearman_vs_hierarchical":
    ↪ reference[method].corr(reference["Q_hierarchical_balanced"], method="spearman")}
196     for fraction in config["top_fractions"]:
197         k = max(1, int(np.ceil(fraction * len(reference))))
198         a = set(reference.nlargest(k, "Q_hierarchical_balanced").record_id)
199         b = set(reference.nlargest(k, method).record_id)
200         row[f"top_{int(100*fraction)}pct_overlap"] = len(a & b) / k
201     ranked = domains[domains.view == "union_unique"].sort_values(method,
    ↪ ascending=False).domain.tolist()
202     row["domain_ranking"] = ">".join(ranked)
203     stability.append(row)
204 pd.DataFrame(stability).to_csv(dest / "quality_method_comparison.csv", index=False)

```

```

205     main_order = domains[domains.view == "union_unique"].sort_values("Q_hierarchical_balanced",
    ↪     ascending=False).domain.tolist()
206     drop_order = domains[domains.view == "union_unique"].sort_values("Q_hierarchical_drop4",
    ↪     ascending=False).domain.tolist()
207     pd.DataFrame({"domain": main_order, "main_rank": range(1,8),
208                  "drop4_rank": [drop_order.index(d)+1 for d in main_order],
209                  "rank_shift": [drop_order.index(d)+1-i for i,d in enumerate(main_order,1)]}).to_csv(dest /
    ↪     "quality_sensitivity.csv", index=False)
210     summary = {"experiment_version": config["experiment_version"], "seed": config["seed"],
211               "valid_unique": int(union.sum()), "accepted_source_rows": len(meta),
212               "new_matrix_vs_v2_max_abs_diff": max_difference,
213               "main_method": "Q_hierarchical_balanced", "fallbacks": fallbacks,
214               "drop4_fallbacks": drop_fallbacks,
215               "max_global_weight": float(wmain.max()),
216               "numerical_chars_weight_v2_1":
    ↪     float(weight_rows.set_index("field").loc["rps_lines_numerical_chars_fraction",
    ↪     "global_weight"]),
217               "numerical_chars_weight_v2": float(old_weights["rps_lines_numerical_chars_fraction"])}
218     save_json(dest / "quality_summary.json", summary)
219     return summary

```

配比距离分层与整簇留出验证: src/q1_revision_v2_1/mixture_validation.py

```

1     """ 冻结 v2 模型后的配方距离、距离分层与配方簇留出验证。 """
2     import json
3     import warnings
4
5     import joblib
6     import numpy as np
7     import pandas as pd
8     from scipy.spatial.distance import cdist
9     from scipy.stats import pearsonr, spearmanr
10    from sklearn.cluster import KMeans
11    from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
12    from sklearn.model_selection import GroupKFold
13
14    from q1.mixture.dataset import load_pair
15    from q1_revision_v2.mixture import model_lgb, ridge_fit, ridge_predict, predict
16    from .common import paths, save_json, sha256
17
18
19    SPLITS = ("train_1m", "test_1m", "test_60m", "test_1b", "est_10b", "est_70b")
20
21
22    def load_data(root, old, old_config):
23        audit = json.loads((old / "audit/audit_summary.json").read_text())
24        xfields, yfields = audit["tables"]["mixture_fields"], audit["tables"]["loss_fields"]
25        data = {name: load_pair(root, name, xfields, yfields, old_config["mixture_sum_tolerance"])[0:3]
26                for name in SPLITS}
27        return data, xfields, yfields
28
29
30    def verify_frozen_model(root, old, config, old_config, data, xfields, yfields, audited_sha):
31        path = old / "mixture/fitted_models.joblib"
32        digest = sha256(path)
33        if digest != audited_sha:

```

```

34     raise RuntimeError("v2 模型文件在本次审计后发生变化")
35 old_meta = json.loads((old / "metadata.json").read_text())
36 anchored = old_meta.get("model_file_sha256")
37 if anchored is not None and anchored != digest:
38     raise RuntimeError("v2 模型文件 SHA 与 v2 metadata 不一致")
39 artifact = joblib.load(path)
40 selected = json.loads((old / "mixture/model_selection.json").read_text())
41 if (artifact["selection"] != selected or artifact["seed"] != config["seed"] or
42     artifact["mix_fields"] != xfields or artifact["loss_fields"] != yfields):
43     raise RuntimeError("冻结模型配置、字段顺序或随机种子不一致")
44 if selected["main_model"] != "LightGBM":
45     raise RuntimeError("v2 主模型并非 LightGBM，停止 v2.1 的指定验证")
46 expected_settings = {"random_state": config["seed"], "bagging_seed": config["seed"],
47                     "feature_fraction_seed": config["seed"], "data_random_seed": config["seed"],
48                     "deterministic": True, "force_col_wise": True}
49 for model in artifact["models"]["LightGBM"]:
50     params = model.get_params()
51     if any(params.get(k) != v for k,v in expected_settings.items()):
52         raise RuntimeError("冻结 LightGBM 随机或确定性参数不一致")
53 ids, x, y = data["test_1m"]
54 old_predictions = pd.read_csv(old / "mixture/predictions_test_1m.csv", dtype={"index":str})
55 if list(old_predictions["index"]) != list(ids):
56     raise RuntimeError("v2 1M 预测行的 index 顺序不一致")
57 differences = {}
58 for kind in ("Ridge", "LightGBM"):
59     actual = predict(artifact["models"][kind], x, kind)
60     expected = old_predictions[[f"predicted_{kind}/{field}" for field in yfields]].to_numpy()
61     max_error = float(np.max(np.abs(actual-expected)))
62     differences[kind] = max_error
63     if not np.allclose(actual, expected, rtol=0, atol=1e-10):
64         raise RuntimeError(f"冻结 {kind} 模型重载后未复现 v2 1M 预测")
65 return artifact, {"model_file_sha256": digest,
66                 "model_hash_anchor_in_v2_metadata": anchored is not None,
67                 "verification_status": "anchored_and_prediction_verified" if anchored else
68                 ↪ "prediction_verified_hash_unanchored",
69                 "prediction_max_abs_diff": differences,
70                 "frozen_params": selected["lightgbm_params"],
71                 "random_settings": expected_settings,
72                 "source": "inherited_from_q1-revision-v2"}
73
74 def nearest_rows(data):
75     ids_train, train, _ = data["train_1m"]
76     rows = []
77     matrix = cdist(train, train, metric="euclidean")
78     np.fill_diagonal(matrix, np.inf)
79     nearest_index = matrix.argmin(axis=1)
80     distance = matrix[np.arange(len(train)), nearest_index]
81     rows.extend({"split": "train_1m", "index": rid, "nearest_train_index": ids_train[j],
82                "nearest_distance": float(d), "distance_rule": "euclidean_17d_leave_self_out"})
83     for rid,j,d in zip(ids_train,nearest_index,distance))
84 for split in SPLITS[1:]:
85     ids, x, _ = data[split]
86     matrix = cdist(x,train,metric="euclidean")
87     nearest_index = matrix.argmin(axis=1)
88     distance = matrix[np.arange(len(x)),nearest_index]

```

```

89     rows.extend({"split":split,"index":rid,"nearest_train_index":ids_train[j],
90                 "nearest_distance":float(d),"distance_rule":"euclidean_17d_to_train"}
91                 for rid,j,d in zip(ids,nearest_index,distance))
92     return pd.DataFrame(rows)
93
94
95     def safe_corr(func, x, y):
96         if len(x)<3 or np.std(x)<1e-12 or np.std(y)<1e-12:
97             return np.nan
98         with warnings.catch_warnings():
99             warnings.simplefilter("ignore")
100             return float(func(x,y).statistic)
101
102
103     def target_metrics(y, pred, yfields):
104         rows=[]
105         for t,field in enumerate(yfields):
106             rows.append({"target":field,"n":len(y),
107                         "rmse":float(np.sqrt(mean_squared_error(y[:,t],pred[:,t])),
108                         "mae":float(mean_absolute_error(y[:,t],pred[:,t])),
109                         "r2":float(r2_score(y[:,t],pred[:,t])),
110                         "pearson":safe_corr(pearsonr,y[:,t],pred[:,t]),
111                         "spearman":safe_corr(spearmanr,y[:,t],pred[:,t])})
112         return rows
113
114
115     def distance_strata(root, old, dest, data, nearest, artifact, yfields):
116         ids,x,y = data["test_1m"]
117         subset = nearest[nearest.split=="test_1m"].copy()
118         if list(subset["index"].astype(str)) != list(ids):
119             raise RuntimeError(" 距离分层与 test_1m index 顺序不一致")
120         subset["distance_quartile"] = pd.qcut(subset.nearest_distance, 4,
121         ↪ labels=["Q1_nearest","Q2","Q3","Q4_farthest"], duplicates="raise")
122         subset.to_csv(dest / "test_1m_distance_quartiles.csv", index=False)
123         train_std = data["train_1m"][2].std(axis=0,ddof=1)
124         detail.summary = [],[]
125         for model_name,models in artifact["models"].items():
126             pred = predict(models,x,model_name)
127             for label in ["Q1_nearest","Q2","Q3","Q4_farthest"]:
128                 mask = (subset.distance_quartile==label).to_numpy()
129                 yy,pp = y[mask],pred[mask]
130                 rows = target_metrics(yy,pp,yfields)
131                 for row in rows:
132                     row.update({"model":model_name,"distance_quartile":label,
133                               "distance_mean":float(subset.loc[mask,"nearest_distance"].mean())})
134                 detail.append(row)
135                 pooled = 1-((yy-pp)**2).sum()/((yy-yy.mean(axis=0))**2).sum()
136                 summary.append({"model":model_name,"distance_quartile":label,"n":int(mask.sum()),
137                               "mean_distance":float(subset.loc[mask,"nearest_distance"].mean()),
138                               "pooled_r2":float(pooled),
139                               "macro_nrmse_train_scale":float(np.mean(np.sqrt(np.mean((yy-pp)**2,axis=0))/train_s
140                               ↪ td)),
141                               "mean_target_pearson":float(np.nanmean([r["pearson"] for r in rows])),
142                               "mean_target_spearman":float(np.nanmean([r["spearman"] for r in rows]))})
143         pd.DataFrame(detail).to_csv(dest / "distance_stratified_metrics.csv", index=False)
144         pd.DataFrame(summary).to_csv(dest / "distance_stratified_summary.csv", index=False)

```

```

143     return summary
144
145
146 def recipe_clusters(x, seed, n_clusters, n_init):
147     """ 函数只接收配比 X，无法读取 Loss；用于固定配方簇。"""
148     model = KMeans(n_clusters=n_clusters, random_state=seed, n_init=n_init)
149     return model.fit_predict(x), model
150
151
152 def cluster_cv(data, xfields, yfields, selection, config, dest, old):
153     ids,x,y = data["train_1m"]
154     labels,kmeans = recipe_clusters(x,config["seed"],config["recipe_kmeans_clusters"],config["recipe_kmeans_n_init"])
155     pd.DataFrame({"index":ids,"cluster":labels}).to_csv(dest / "cluster_assignments.csv",index=False)
156     folds = list(GroupKFold(n_splits=config["recipe_group_cv_folds"]).split(x,y,labels))
157     fold_rows=[]
158     details=[]
159     summaries=[]
160     global_std=y.std(axis=0,ddof=1)
161     for fold,(tr,va) in enumerate(folds):
162         if set(labels[tr]) & set(labels[va]):
163             raise RuntimeError(" 配方簇泄漏到同一 GroupKFold 的训练和验证侧")
164         fold_rows.extend({"fold":fold,"row":int(i),"index":ids[i],"cluster":int(labels[i]),"role":role}
165                         for role,values in (("train",tr),("validation",va)) for i in values)
166         preds={}
167         preds["Ridge"]=np.column_stack([ridge_predict(ridge_fit(x[tr],y[tr,t],selection["ridge_alphas_by_target"],
168                                     rget[t]),x[va])
169                                     for t in range(y.shape[1])])
170         preds["LightGBM"]=np.column_stack([model_lgb(selection["lightgbm_params"],config["seed"]).fit(
171                                     x[tr],y[tr,t]).predict(x[va])
172                                     for t in range(y.shape[1])])
173         for name,pred in preds.items():
174             rows=target_metrics(y[va],pred,yfields)
175             for row in rows:
176                 row.update({"fold":fold,"model":name,"n_train":len(tr),"n_validation":len(va),
177                             "alpha_or_params":"frozen_v2"})
178                 details.append(row)
179                 pooled=1-(((y[va]-pred)**2).sum()/((y[va]-y[va].mean(axis=0))**2).sum())
180                 summaries.append({"fold":fold,"model":name,"n_train":len(tr),"n_validation":len(va),
181                                 "macro_nrmse_train_scale":float(np.mean(np.sqrt(np.mean((y[va]-pred)**2,axis=0))/
182                                     global_std)),
183                                 "pooled_r2":float(pooled),"mean_target_pearson":float(np.nanmean([r["pearson"] for r
184                                     in rows]))})
185     pd.DataFrame(fold_rows).to_csv(dest / "cluster_cv_fold_membership.csv",index=False)
186     pd.DataFrame(details).to_csv(dest / "cluster_cv_metrics.csv",index=False)
187     pd.DataFrame(summaries).to_csv(dest / "cluster_cv_fold_summary.csv",index=False)
188     old_cv=pd.read_csv(old / "mixture/cv_fold_metrics.csv")
189     random_summary=[]
190     for name,key in (("Ridge","ridge_rmse"),("LightGBM","lightgbm_rmse")):
191         mean_by_target=old_cv.groupby("target_index")[key].apply(lambda
192                             s:np.sqrt(np.mean(s**2))).to_numpy()
193         random_summary.append({"evaluation":"random_repeated_cv_v2","model":name,
194                               "macro_nrmse_train_scale":float(np.mean(mean_by_target/global_std)),
195                               "n_folds":int(old_cv.fold.nunique())})
196     cluster_by_model=pd.DataFrame(summaries).groupby("model",as_index=False).macro_nrmse_train_
197     scale.mean()

```

```

192     for row in cluster_by_model.itertuples():
193         random_summary.append({"evaluation": "cluster_group_cv_v2_1", "model": row.model,
194                                "macro_nrmse_train_scale": float(row.macro_nrmse_train_scale), "n_folds": len(folds)})
195     pd.DataFrame(random_summary).to_csv(dest / "random_vs_cluster_cv.csv", index=False)
196     return {"cluster_count": len(set(labels)), "fold_count": len(folds),
197            "frozen_lightgbm_params": selection["lightgbm_params"], "frozen_ridge_alphas": selection["ridge_α_αphas_by_target"]}
198
199
200 def run(root, config, old_config):
201     root, out, old = paths(root)
202     dest = out / "mixture"
203     dest.mkdir(parents=True, exist_ok=True)
204     audit = json.loads((out / "audit/audit_summary.json").read_text())
205     data, xfields, yfields = load_data(root, old, old_config)
206     selection = json.loads((old / "mixture/model_selection.json").read_text())
207     artifact, reference = verify_frozen_model(root, old, config, old_config, data, xfields, yfields,
208                                              audit["v2_model_file_sha256"])
209     save_json(dest / "inherited_v2_model_reference.json", reference)
210     nearest = nearest_rows(data)
211     nearest.to_csv(dest / "nearest_train_distance.csv", index=False)
212     stats = nearest.groupby("split").nearest_distance.agg(
213         n="count", mean="mean", median="median", q05=lambda a: a.quantile(.05),
214         q25=lambda a: a.quantile(.25), q75=lambda a: a.quantile(.75),
215         q95=lambda a: a.quantile(.95), maximum="max").reset_index()
216     stats.to_csv(dest / "nearest_train_distance_summary.csv", index=False)
217     strata = distance_strata(root, old, dest, data, nearest, artifact, yfields)
218     cluster = cluster_cv(data, xfields, yfields, selection, config, dest, old)
219     return {"model_reference": reference, "distance_summary": stats.to_dict(orient="records"),
220           "cluster_cv": cluster}

```

B.2 问题二：质量扩展标度律

参数约束、多起点拟合及预测函数：src/q2_v2/model.py

```

1  """B1/B6 标度律的带约束多起点估计和组级验证。"""
2  from __future__ import annotations
3
4  import json
5  from pathlib import Path
6
7  import numpy as np
8  from scipy.optimize import least_squares
9  from scipy.stats import pearsonr, spearmanr
10 from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
11 from sklearn.model_selection import GroupKFold, LeaveOneGroupOut
12
13
14 SEED = 7
15 POSITIVE = ["A", "B", "alpha", "beta"]
16
17
18 def predict(theta: dict, n, d, q=None, q0=None, form="base", h=0.0, lam=0.0):
19     n, d = np.asarray(n, float), np.asarray(d, float)
20     p = theta["A"] * n ** (-theta["alpha"])
21     t = theta["B"] * d ** (-theta["beta"])
22     if form == "base":

```

```

23     return theta["E"] + p + t
24     z = np.asarray(q0 - np.asarray(q, float), float)
25     g = theta.get("gamma", 0.0) * z + theta.get("gamma2", 0.0) * z * z
26     if form == "quality" or form == "A":
27         return theta["E"] + p + t * np.exp(g + lam * h)
28     if form == "B":
29         return theta["E"] + (p + t * np.exp(g)) * np.exp(lam * h)
30     raise ValueError(form)
31
32
33 def unpack(x, quality=False, quadratic=False):
34     out = dict(E=float(x[0]), A=float(np.exp(x[1])), B=float(np.exp(x[2])), alpha=float(np.exp(x[3])),
35         ↪ beta=float(np.exp(x[4])))
36     if quality:
37         out["gamma"] = float(x[5])
38     if quadratic:
39         out["gamma2"] = float(x[6])
40     return out
41
42 def fit(frame, quality=False, q0=None, quadratic=False, starts=4, seed=SEED):
43     """ 对正参数取 log, E 采用非负边界。初值仅取训练折。 """
44     n = frame.N_params_B.to_numpy(float)
45     d = frame.D_tokens_B.to_numpy(float)
46     y = frame.val_loss.to_numpy(float)
47     q = frame.Q_score.to_numpy(float) if quality else None
48     if not (np.isfinite(n).all() and np.isfinite(d).all() and np.isfinite(y).all() and (n > 0).all() and (d > 0).all()):
49         raise ValueError("invalid N/D/Loss")
50     if quality and q0 is None:
51         raise ValueError("Q reference must be fixed")
52     rng = np.random.default_rng(seed)
53     e0 = max(0.01, float(np.min(y) * 0.65))
54     base = np.array([e0, np.log(max(.1, np.std(y))), np.log(max(.1, np.std(y))), np.log(.3), np.log(.3)] + ([.1]
55         ↪ if quality else []) + ([0.] if quadratic else []))
56     lo = [0, -12, -12, np.log(.01), np.log(.01)] + ([-10] if quality else []) + ([-20] if quadratic else [])
57     hi = [max(10, float(np.max(y) * 2)), 5, 5, np.log(3), np.log(3)] + ([10] if quality else []) + ([20] if
58         ↪ quadratic else [])
59     runs = []
60     for i in range(starts):
61         x0 = base.copy()
62         if i:
63             x0[0] *= rng.uniform(.4, 1.4)
64             x0[1:5] += rng.normal(0, .55, 4)
65             if quality:
66                 x0[5] = rng.normal(0, .5)
67         x0 = np.clip(x0, np.asarray(lo) + 1e-7, np.asarray(hi) - 1e-7)
68         def residual(x):
69             t = unpack(x, quality, quadratic)
70             return predict(t, n, d, q, q0, "quality" if quality else "base") - y
71         res = least_squares(residual, x0, bounds=(lo, hi), max_nfev=2500, ftol=1e-10, xtol=1e-10)
72         runs.append(dict(start=i, initial_values=json.dumps(unpack(x0, quality, quadratic)),
73             ↪ final_values=json.dumps(unpack(res.x, quality, quadratic)), converged=bool(res.success),
74             ↪ objective=float(np.sum(res.fun ** 2)), iterations=int(res.nfev), x=res.x))
75     good = [r for r in runs if r["converged"]]
76     if not good:
77         raise RuntimeError("all nonlinear fits failed")

```

```

74     best = min(good, key=lambda r: r["objective"])
75     theta = unpack(best["x"], quality, quadratic)
76     for r in runs:
77         del r["x"]
78     return theta, runs
79
80
81 def metrics(y, pred):
82     y, pred = np.asarray(y, float), np.asarray(pred, float)
83     return dict(n=len(y), RMSE=float(np.sqrt(mean_squared_error(y, pred))),
84         ↪ MAE=float(mean_absolute_error(y, pred)), R2=float(r2_score(y, pred)) if len(y) > 1 else None,
85         ↪ Pearson=float(pearsonr(y, pred).statistic) if len(y) > 2 and np.std(y) and np.std(pred) else None,
86         ↪ Spearman=float(spearmanr(y, pred).statistic) if len(y) > 2 and np.std(y) and np.std(pred) else
87         ↪ None, mean_bias=float(np.mean(pred-y)))
88
89
90 def cv(frame, group, quality=False, q0=None, quadratic=False, n_splits=None):
91     splitter = GroupKFold(n_splits=n_splits) if n_splits else LeaveOneGroupOut()
92     rows, predictions = [], []
93     for fold, (tr, te) in enumerate(splitter.split(frame, groups=group)):
94         train, test = frame.iloc[tr], frame.iloc[te]
95         theta, _ = fit(train, quality, q0, quadratic, seed=SEED + fold, starts=3)
96         yhat = predict(theta, test.N_params_B, test.D_tokens_B, test.Q_score if quality else None, q0,
97             ↪ "quality" if quality else "base")
98         rows.append(dict(fold=fold, test_groups="|".join(sorted(set(np.asarray(group)[te].astype(str)))),
99             ↪ model="MQ2" if quadratic else "MQ" if quality else "M0", **metrics(test.val_loss, yhat)))
100         predictions.extend(dict(fold=fold, source_row=int(i), group=str(np.asarray(group)[i]),
101             ↪ actual=float(test.loc[i].val_loss), prediction=float(v)) for i,v in zip(test.index,yhat))
102     return rows, predictions
103
104
105 def grouped_bootstrap(frame, group, quality=False, q0=None, reps=60):
106     groups = np.asarray(group).astype(str)
107     unique = np.unique(groups)
108     rng = np.random.default_rng(SEED)
109     rows = []
110     for i in range(reps):
111         picks = rng.choice(unique, len(unique), replace=True)
112         positions = np.concatenate([np.flatnonzero(groups == g) for g in picks])
113         try:
114             theta, _ = fit(frame.iloc[positions], quality, q0, starts=2, seed=SEED + i)
115             rows.append(dict(bootstrap=i, **theta))
116         except RuntimeError:
117             continue
118     return rows
119
120
121 def save_csv(path: Path, rows, columns=None):
122     import pandas as pd
123     path.parent.mkdir(parents=True, exist_ok=True)
124     pd.DataFrame(rows, columns=columns).to_csv(path, index=False)
125
126
127 def save_json(path: Path, obj):
128     path.parent.mkdir(parents=True, exist_ok=True)
129     path.write_text(json.dumps(obj, ensure_ascii=False, indent=2, allow_nan=False))

```

B.3 问题三：算力预算情景求解

最新情景网格、质量成本函数与受约束求解：src/q3_latest/pipeline.py

```
1  """ 基于 q2-fusion-rerun-v1 和正式 Q1 接口重跑问题三。 """
2  from __future__ import annotations
3
4  import hashlib
5  import json
6  from pathlib import Path
7
8  import numpy as np
9  import pandas as pd
10 from scipy.optimize import minimize
11
12
13 ROOT = Path(__file__).resolve().parents[2]
14 OUT = ROOT / "results/q3_latest_20260926"
15 Q2 = ROOT / "results/q2_fusion_rerun_v1"
16 Q1 = ROOT / "results/q1_revision_v2_1/q2_interface"
17 VERSION = "q3-latest-20260926-v1"
18 SEED = 20260926
19
20 BUDGETS = [1e19, 1e22, 1e24]
21 CONTEXTS = [2048, 4096, 8192, 32768, 131072]
22 ETAS = [1e-4, 2e-4, 4e-4]
23 COST_TYPES = ["exp", "pow", "log"]
24 BOX = {"N": (0.07, 11.97), "D": (10.0, 600.0), "Q": (0.5, 1.0)}
25
26
27 def sha256(path: Path):
28     h = hashlib.sha256()
29     with path.open("rb") as stream:
30         for block in iter(lambda: stream.read(1 << 20), b''):
31             h.update(block)
32     return h.hexdigest()
33
34
35 def write_json(path: Path, value: dict):
36     path.parent.mkdir(parents=True, exist_ok=True)
37     path.write_text(json.dumps(value, ensure_ascii=False, indent=2, default=float), encoding="utf-8")
38
39
40 def quality_cost(kind: str, q):
41     q = np.asarray(q, float)
42     if kind == "exp":
43         return 1e7 * np.exp(6 * q)
44     if kind == "pow":
45         return 5e9 * q**4
46     if kind == "log":
47         return 2e9 * np.log1p(10 * q)
48     raise ValueError(kind)
49
50
51 def loss(params: dict, n, d, q, h=0.0, lambda_p=0.0):
52     """Q2 主模型 Form A; 配比只作为显式情景作用于数据项。"""
53     return (params["E"] + params["A"] * np.asarray(n) ** (-params["alpha"]))
```

```

54         + params["B"] * np.asarray(d) ** (-params["beta"])
55         * np.exp(params["gamma"] * (params["q0"] - np.asarray(q)) + lambda_p * h))
56
57
58 def equivalent_legacy_parameters(params: dict):
59     """ 给出与旧八参数计算器严格等价的参数，仅用于可复核迁移。 """
60     return {
61         "E": params["E"], "A": params["A"], "alpha": params["alpha"],
62         "B": params["B"] * np.exp(params["gamma"] * params["q0"]),
63         "beta": params["beta"], "rho_N": 0.0, "rho_D": params["gamma"], "E1": 0.0,
64     }
65
66
67 def solve_box(params: dict, budget: float, context: int, eta: float, cost_type: str,
68              h: float = 0.0, lambda_p: float = 0.0, nd: int = 260, nq: int = 220):
69     nmin, nmax = BOX["N"]
70     dmin, dmax = BOX["D"]
71     q0, qmax = BOX["Q"]
72     c18 = budget / 1e18
73     k = 6 + eta * context
74     if c18 < k * nmin * dmin:
75         return None
76
77     def scan(dlo, dhi, qlo, qhi, nd_, nq_):
78         ds = np.linspace(dlo, dhi, nd_)
79         best = None
80         for q in np.linspace(qlo, qhi, nq_):
81             psi = max(float(quality_cost(cost_type, q) - quality_cost(cost_type, q0)), 0.0) / 1e9
82             ns = np.minimum(nmax, (c18 / ds - psi) / k)
83             valid = ns >= nmin
84             if not valid.any():
85                 continue
86             values = loss(params, ns[valid], ds[valid], q, h, lambda_p)
87             pos = int(np.argmax(values))
88             candidate = (float(values[pos]), float(ns[valid][pos]), float(ds[valid][pos]), float(q))
89             if best is None or candidate[0] < best[0]:
90                 best = candidate
91         return best
92
93     best = scan(dmin, dmax, q0, qmax, nd, nq)
94     if best is None:
95         return None
96     for _ in range(2):
97         dstep = (dmax - dmin) / nd * 5
98         qstep = (qmax - q0) / nq * 5
99         refined = scan(max(dmin, best[2] - dstep), min(dmax, best[2] + dstep),
100                      max(q0, best[3] - qstep), min(qmax, best[3] + qstep), 300, 260)
101         if refined and refined[0] < best[0]:
102             best = refined
103     nd, nq = 300, 260
104     value, n, d, q = best
105     psi = max(float(quality_cost(cost_type, q) - quality_cost(cost_type, q0)), 0.0) / 1e9
106     used = d * (k * n + psi)
107     shares = {"train": 6*n*d/c18, "attention": eta*context*n*d/c18, "quality": d*psi/c18}
108     return {
109         "N": n, "D": d, "Q": q, "L": value, "budget_used_fraction": used/c18,

```

```

110     "idle_fraction": max(0.0, 1-used/c18), "s_train": shares["train"],
111     "s_attention": shares["attention"], "s_quality": shares["quality"],
112     "dominant_cost": max(shares, key=shares.get),
113     "N_status": "min" if np.isclose(n, nmin, atol=1e-5) else "max" if np.isclose(n, nmax, atol=1e-5) else
    ↪     "interior",
114     "D_status": "min" if np.isclose(d, dmin, atol=1e-4) else "max" if np.isclose(d, dmax, atol=1e-4) else
    ↪     "interior",
115     "Q_status": "reference" if np.isclose(q, q0, atol=1e-5) else "max" if np.isclose(q, qmax, atol=1e-5)
    ↪     else "interior",
116 }
117
118
119 def verify_local(params: dict, row: pd.Series):
120     if not row.feasible:
121         return {"checked": False, "reason": "infeasible"}
122     c18 = row.C / 1e18
123     k = 6 + row.eta * row.Lctx
124     q0 = params["q0"]
125     def objective(x):
126         return float(loss(params, x[0], x[1], x[2]))
127     def remaining(x):
128         psi = max(float(quality_cost(row.cost_type, x[2]) - quality_cost(row.cost_type, q0)), 0.0)/1e9
129         return c18 - x[1]*(k*x[0]+psi)
130     result = minimize(objective, [row.N,row.D,row.Q], method="SLSQP",
131                       bounds=[BOX["N"],BOX["D"],BOX["Q"]],
132                       constraints=[{"type":"ineq", "fun":remaining}],
133                       options={"ftol":1e-11,"maxiter":2000})
134     rel = (row.L-float(result.fun))/max(abs(row.L),1e-12)
135     return {"checked": True, "success": bool(result.success), "local_loss": float(result.fun),
136           "grid_loss": float(row.L), "relative_improvement": float(rel),
137           "budget_remaining_C18": float(remaining(result.x))}
138
139
140 def run():
141     OUT.mkdir(parents=True, exist_ok=True)
142     params_raw = json.loads((Q2/"quality_model/b6_parameters.json").read_text())
143     params = dict(params_raw["MQ"], q0=float(params_raw["q0"]))
144     q1_manifest = json.loads((Q1/"manifest.json").read_text())
145     if q1_manifest["status"] != "PASS":
146         raise RuntimeError("Q1 formal interface is not PASS")
147     interface = pd.read_csv(ROOT/q1_manifest["mixture_response_path"])
148
149     transformed = equivalent_legacy_parameters(params)
150     probes = pd.DataFrame({"N": [1,1,10], "D": [10,100,600], "Q": [.5,.7,1.]})
151     direct = loss(params, probes.N, probes.D, probes.Q)
152     legacy = (transformed["E"] + transformed["A"]*probes.N**(-transformed["alpha"])
153             + transformed["B"]*probes.D**(-transformed["beta"])*np.exp(-transformed["rho_D"]*probes.Q))
154     transform_error = float(np.max(np.abs(direct-legacy)))
155     if transform_error > 1e-12:
156         raise RuntimeError("Q2 parameter transform is not equivalent")
157     write_json(OUT/"parameter_transform.json",
158             ↪     {"source_formula": "E+A*N^(-alpha)+B*D^(-beta)*exp(gamma*(q0-Q))",
159              "optimization_formula": "E+A*N^(-alpha)+B_eff*D^(-beta)*exp(-rho_D*Q)",
160              "source_parameters": params, "equivalent_parameters": transformed, "max_abs_probe_error": transform_
    ↪     m_error})

```

```

161 rows=[]
162 for eta in ETAS:
163     for context in CONTEXTS:
164         for cost_type in COST_TYPES:
165             for budget in BUDGETS:
166                 result=solve_box(params,budget,context,eta,cost_type)
167                 record={"eta":eta,"Lctx":context,"cost_type":cost_type,"C":budget,"feasible":result is not
                    ↪ None}
168                 if result: record.update(result)
169                 rows.append(record)
170 grid=pd.DataFrame(rows)
171 grid.to_csv(OUT/"scenario_grid_all.csv",index=False)
172 grid[np.isclose(grid.eta,2e-4)].to_csv(OUT/"scenario_grid_main.csv",index=False)
173
174 # 问题四机制腿使用的局部总 Loss 预算弹性；固定在主情景中档预算工作点。
175 eps_step=.01
176 low=solve_box(params,1e22*np.exp(-eps_step),32768,2e-4,"exp",nd=400,nq=350)
177 high=solve_box(params,1e22*np.exp(eps_step),32768,2e-4,"exp",nd=400,nq=350)
178 epsilon_total=float((np.log(high["L"])-np.log(low["L"]))/(2*eps_step))
179 mechanism={"C":1e22,"Lctx":32768,"eta":2e-4,"cost_type":"exp",
180            "definition":"d log(total Loss*) / d log(C)","epsilon_C":epsilon_total,
181            "finite_difference_log_step":eps_step,"low":low,"high":high}
182 write_json(OUT/"mechanism_elasticity.json",mechanism)
183
184 # LightGBM 不可微，配比只在正式接口的观测/估算配方与 p0 上做离散情景比较。
185 mix=interface[["split","data_role","index","nearest_train_distance","support_status","h_agg"]].copy()
186 mix.insert(0,"recipe_id",[f"{s}:{int(i)}" for s,i in zip(mix.split,mix["index"])])
187 mix=pd.concat([pd.DataFrame([{"recipe_id":"p0","split":"reference","data_role":"reference",
188                               "index":0,"nearest_train_distance":0.0,"support_status":"within_support","h_agg":0.0}]),mix],ignor_
                    ↪ e_index=True)
189 base=solve_box(params,1e22,32768,2e-4,"exp")
190 scenario=[]
191 for lam in (0,.5,1,1.5):
192     for _,r in mix.iterrows():
193         scenario.append({**r.to_dict(),"lambda_p":lam,"conditional_loss":float(loss(params,base["N"],b_
                    ↪ ase["D"],base["Q"],r.h_agg,lam))})
194 mix_scen=pd.DataFrame(scenario)
195 mix_scen.to_csv(OUT/"mixture_scenarios.csv",index=False)
196
197 # 直接传播 Q2 的组 bootstrap 参数，不在 Q3 重新窥视 B7/B8。
198 boot=pd.read_csv(Q2/"quality_model/b6_bootstrap_parameters.csv")
199 boot_rows=[]
200 for _,r in boot.iterrows():
201     bp={k:float(r[k]) for k in ("E","A","B","alpha","beta","gamma")};bp["q0"]=params["q0"]
202     opt=solve_box(bp,1e22,32768,2e-4,"exp",nd=140,nq=120)
203     if opt: boot_rows.append({"bootstrap":int(r.bootstrap),**{k:opt[k] for k in ("N","D","Q","L")}})
204 pd.DataFrame(boot_rows).to_csv(OUT/"bootstrap_optima.csv",index=False)
205
206 checks=[]
207 feasible=grid[grid.feasible].reset_index(drop=True)
208 for pos in np.linspace(0,len(feasible)-1,9,dtype=int):
209     row=feasible.iloc[pos]
210     checks.append({"row":int(pos),"eta":row.eta,"Lctx":int(row.Lctx),"cost_type":row.cost_type,"C":ro_
                    ↪ w.C,**verify_local(params,row)})
211 check_frame=pd.DataFrame(checks)
212 check_frame.to_csv(OUT/"kkt_local_verification.csv",index=False)

```

```

213 kkt_pass=bool(check_frame.success.all() and (check_frame.relative_improvement < 2e-5).all() and
    ↪ (check_frame.budget_remaining_C18 >= -1e-6).all())
214
215 sources=[Q2/"quality_model/b6_parameters.json",Q2/"quality_model/b6_bootstrap_parameters.csv",Q
    ↪ 1/"manifest.json",ROOT/q1_manifest["mixture_response_path"]]
216 products=[OUT/"parameter_transform.json",OUT/"scenario_grid_all.csv",OUT/"scenario_grid_main.c
    ↪ sv",OUT/"mechanism_elasticity.json",OUT/"mixture_scenarios.csv",OUT/"bootstrap_optima.csv"
    ↪ ",OUT/"kkt_local_verification.csv"]
217 status="PASS_WITH_WARNINGS" if kkt_pass else "BLOCKED"
218 metadata={"version":VERSION,"latest":True,"status":status,"seed":SEED,
219     "upstream":{"q2":"q2-fusion-rerun-v1","q1_interface":q1_manifest["interface_version"]},
220     "source_sha256":{str(p.relative_to(ROOT)):sha256(p) for p in sources},
221     "product_sha256":{str(p.relative_to(ROOT)):sha256(p) for p in products},
222     "counts":{"grid":len(grid),"feasible":int(grid.feasible.sum()),"infeasible":int((~grid.feasible).sum()),
    ↪ "mixture_recipes":len(mix),"bootstrap_success":len(boot_rows),"kkt_checks":len(checks)},
223     "checks":{"formal_q1_interface":True,"parameter_transform_max_abs_error":transform_error,"kkt"
    ↪ _local_pass":kkt_pass,"mechanism_epsilon_finite":bool(np.isfinite(epsilon_total))},
224     "assumptions":{"quality_cost":"three uncalibrated scenarios","eta":"scenario","lambda_p":"scenario"
    ↪ _not_identified","mixture_optimization":"discrete formal-interface candidates; not global causal
    ↪ optimum"}}}
225 write_json(OUT/"metadata.json",metadata)
226 write_json(OUT/"LATEST_VERSION.json",{ "latest":True,"version":VERSION,"status":status,"super"
    ↪ sedes":"results/q3 and 团队交付包_问题三融合方案.zip"})
227 main=grid[np.isclose(grid.eta,2e-4)]
228 bdf=pd.DataFrame(boot_rows)
229 report=["# 问题三融合方案 | 最新版 2026-09-26","",f"**LATEST / 当前最新版**：`{VERSION}`";
    ↪ 状态`{status}`。","",
230     "本版使用问题二`q2-fusion-rerun-v1`的MQ主模型和问题一正式LightGBM接口；不再使用
    ↪ q2_v8 SET_A 或 mix_final_model_quad.csv。","",
231     "## 重跑摘要","",f"- 情景网格 {len(grid)} 行：可行 {int(grid.feasible.sum())}，不可行
    ↪ {int((~grid.feasible).sum())}。",f"- 主  $\eta=2e-4$  网格 {len(main)} 行。",f"- Q2 组 bootstrap
    ↪ 传播成功 {len(bdf)}/{len(boot)} 次。",f"- 局部数值/KKT 复核 {len(checks)} 点，
    ↪ 验收={kkt_pass}。",f"- 参数化等价转换最大绝对误差 {transform_error:.3e}。",f"- Q4
    ↪ 机制腿工作点的总 Loss 预算弹性 epsilon_C={epsilon_total:.8f}。","",
232     "## 配比结论","",f"正式接口中加入 p0 后候选 h_agg 范围 [{mix.h_agg.min():.6g},
    ↪ {mix.h_agg.max():.6g}]。当前 LightGBM 接口下 p0 是这些离散候选的最小值；
    ↪ 这不是连续单纯形上的全局最优证明。lambda_p 仍只取情景值。","",
233     "## 证据边界","",f"质量成本函数、eta 与 lambda_p 均未由联合实验识别；高预算解常触及 N/D
    ↪ 支持边界。所有最优值是给定模型与成本情景的条件解。","",
234     f"Q3 LATEST STATUS: {status}","",
235     (OUT/"report.md").write_text("\n".join(report),encoding="utf-8")
236     (OUT/"README_LATEST.md").write_text("# LATEST | 问题三最新版\n\n唯一推荐入口：
    ↪ `PYTHONPATH=src.venv/bin/python -m src.q3_latest.pipeline`。 \n\n查看
    ↪ `LATEST_VERSION.json`、`metadata.json` 和 `report.md`。 \n",encoding="utf-8")
237 return metadata
238
239
240 if __name__ == "__main__":
241     result=run()
242     print(f"Q3_LATEST_STATUS: {result['status']}")

```

B.4 问题四：版本动态与分轨情景

版本统一动态模型核心程序：src/q4_latest/version_aligned_dynamics.py

```

1 """Quality-weighted auxiliary cohorts with nested lineage validation and explicit clocks."""

```

```

2 from pathlib import Path
3 import json,zipfile,io,datetime,hashlib,re
4 import numpy as np,pandas as pd
5 from scipy.special import expit
6 from scipy.optimize import least_squares
7 R=Path(__file__).resolve().parents[2];O=R'/Users/lucasliao/Documents/Codex/2026-09-25/pao/outputs/
    ↳ 第四问方案重跑_20260926_162328/版本时间统一模型';O.mkdir(exist_ok=True)
8 S=R'/outputs/第四问自定义开源口径_2026-09-26/O口径主样本.csv';Z=R'/outputs/第四问交接包_联
    ↳ 合校准版_2026-09-26/data/第四问复跑附件子集.zip';J=R'/outputs/第四问继续建模_2026-09-26/
    ↳ q4_c2_official_sha_rowlink.json';V=R'/outputs/第四问版本日期补证_2026-09-26/audit.json'
9 T=['IFEval','BBH','MATH Lvl 5','GPQA','MUSR','MMLU-PRO']
10 with zipfile.ZipFile(Z) as z:raw=z.read('F06ÿ/real_attachments/C_efficiency_evolution/leaderboard_enh
    ↳ anced.csv');lb=pd.read_csv(io.BytesIO(raw));lb['c2_row']=lb.index
11 rowlink=pd.DataFrame(json.loads(J.read_text())['rows']);d=lb.merge(rowlink[['C2_row_index','row_iden
    ↳ tity_verified','model_sha','official_upload_date']],left_on='c2_row',right_on='C2_row_index')
12 d['model']=d.Model;d['publisher']=d.model.str.split('/').str[0];d['track']=d.Type.map(lambda v:'pretrained'
    ↳ if 'pretrained' in str(v) else 'chat_finetuned' if ('chat models' in str(v) or 'fine-tuned' in str(v)) else
    ↳ 'excluded')
13 VA=R'/outputs/第四问版本日期补证_2026-09-26/auxiliary_audit.json'
14 version_records=json.loads(V.read_text())['records']+json.loads(VA.read_text())['records']
15 version_dates={};latest_dates={}
16 for record in version_records:
17     if not record.get('sha_match') or not record.get('weight_timestamps_complete'):continue
18     by_format={}
19     for f in record.get('weight_file_dates',[]):
20         date=(f.get('commit') or {}).get('date')
21         if date:by_format.setdefault(Path(f['path']).suffix,[]).append(date)
22     if by_format:
23         version_dates[(record['model'],record['revision'])]=min(max(vals) for vals in by_format.values())
24         latest_dates[(record['model'],record['revision'])]=max(max(vals) for vals in by_format.values())
25 d['version_date_evidence']=[version_dates.get((r.model,r.model_sha)) for r in d.itertuples()]
26 d['date']=pd.to_datetime(d.version_date_evidence,errors='coerce',utc=True).dt.tz_localize(None).dt.norm
    ↳ alize();d['submission']=pd.to_datetime(d['Submission
    ↳ Date'],errors='coerce');d['logN']=np.log(pd.to_numeric(d['#Params
    ↳ (B)'],errors='coerce')).where(lambda
    ↳ x:x>0);d['chat']=d.track.eq('chat_finetuned').astype(float);d['score']=d[T].mean(axis=1)
27 def lineage(n):
28     n=n.lower()
29     for tag in ['qwen','llama','pythia','gpt-neo','gpt-j','smollm','yi-','phi-','mistral','gemma','deepseek','olmo','fal
    ↳ con','bloom','opt-','stablelm','k2']:
30         if tag in n:return tag
31     return 'publisher:'+n.split('/')[0]
32 d['lineage']=d.model.map(lineage)
33 d['usable']=(d.Epoch_AI_Open_Weights.eq('Yes') & d.track.ne('excluded') & d.row_identity_verified &
    ↳ d.model_sha.str.len().eq(40) & d.date.notna() & d.submission.notna() & d.date.le(d.submission) &
    ↳ d.submission.le(pd.Timestamp('2025-03-13')) & np.isfinite(d.logN) & np.isfinite(d[T]).all(axis=1) &
    ↳ d[T].ge(0).all(axis=1) & d[T].le(100).all(axis=1) & d.model.ne('microsoft/phi-4'))
34 original=pd.read_csv(S);ids=set(original.c2_row);d['is_O']=d.c2_row.isin(ids);d['source_aux']=(~d.is_O)
    ↳ .astype(float)
35 d=d[d.usable].sort_values(['model','model_sha','c2_row']).drop_duplicates(['model','model_sha']).copy();
    ↳ d['time']=(d.date-pd.Timestamp('2020-01-01')).dt.days/365.25
36 # O protocol offsets remain traceable; auxiliary protocol is explicitly unknown.
37 proto=original.set_index('c2_row').apply(lambda x:str(x.protocol_fingerprint)+'/'+str(x.harness_hash),axi
    ↳ s=1).to_dict();d['protocol']=d.c2_row.map(proto).fillna('AUX_UNKNOWN')
38 core=d[d.is_O].reset_index(drop=True);aux=d[~d.is_O &
    ↳ ~d.model.isin(original.model)].reset_index(drop=True)

```

```

39 core.to_csv(O/O主样本_版本制品时间.csv',index=False,encoding='utf-8-sig');aux.to_csv(O/辅助样本_
    ↪ _非O资格.csv',index=False,encoding='utf-8-sig')
40 # Independent fixed-revision artifact clocks (never silently called release dates).
41 vr={x['model']:x for x in json.loads(V.read_text())['records']};audit=[]
42 for row in original.itertuples():
43     v=vr[row.model];formats={ }
44     for f in v.get('weight_file_dates',[]):
45         ext=Path(f['path']).suffix;dates=formats.setdefault(ext,[]);date=(f.get('commit') or { }).get('date')
46         if date:dates.append(date)
47     readiness={ext:max(dates) for ext,dates in formats.items() if dates};first=min(readiness.values()) if
    ↪     readiness else None
48     audit.append({ 'c2_row':row.c2_row,'model':row.model,'repository_created':v.get('repository_created'),'fi
    ↪     rst_format_ready':first,'latest_format_update':v.get('latest_weight_file_commit'),'revision_commit':
    ↪     v.get('revision_commit_date'),'all_weight_dates_present':v.get('weight_timestamps_complete'),'sam
    ↪     e_content_across_formats_verified':False,'formats':json.dumps(readiness),'conversion_commit_see'
    ↪     n':any('safetensors' in (f.get('commit') or { }).get('title','')).lower() for f in
    ↪     v.get('weight_file_dates',[])} })
49 audit=pd.DataFrame(audit);audit.to_csv(O/固定版本时间口径对照.csv',index=False,encoding='utf-8-si
    ↪     g')
50 GRID=[(a,b,w) for a in [1.,10.,100.] for b in [10.,100.,1000.] for w in [0.,25,1.]]
51 contract={'created_before_fit':datetime.datetime.now(datetime.timezone.utc).isoformat(),'primary_clock':
    ↪     'earliest ready weight-format timestamp at fixed evaluation revision, both primary and auxiliary;
    ↪     artifact availability proxy, not certified first public release','main':'100*sigmoid(latent response),
    ↪     score-space weighted squared error with training-mean slope-scaled ridge penalties; auxiliary, type,
    ↪     time and protocol controls','auxiliary_not_O':True,'aux_total_weight':'w * number of core training
    ↪     rows; evenly across auxiliary lineage groups then within
    ↪     group','grid':GRID,'same_family_exclusion':'outer lineage folds exclude held lineage from BOTH
    ↪     core and auxiliaries; publisher folds purge held publisher and held lineages from auxiliaries; inner
    ↪     folds always exclude lineage','chronology':'for chronological holdout, auxiliaries must have both
    ↪     upload and submission dates earlier than cutoff; rolling inner splits obey
    ↪     same','cv_choice':'lineage-balanced MAE inside outer training; latest-cohort outer uses rolling-origin
    ↪     inner selection if >=2 folds available','no_score_clipping':True,'success_criteria':'compare with
    ↪     identical core-only nested baseline and constant on same heldout rows; report all designs, do not pick
    ↪     clock by score','clock_sensitivity':['official hub upload','first listed weight format ready','latest weight
    ↪     format update'],'claims':'exploratory repeated data; no causal/long-horizon coverage certification'}
52 (O/contract.json').write_text(json.dumps(contract,ensure_ascii=False,indent=2))
53 # Cached matrix construction for fast grid search.
54 def prepare(c,a,e,temporal=True):
55     cols=['logN','chat']+(['time'] if temporal else [])
56     mu=c[cols].mean().to_numpy();sd=c[cols].std(ddof=0).to_numpy().copy();sd[sd<1e-8]=1
57     pc=sorted(c.protocol.unique());freq=c.protocol.value_counts(normalize=True).reindex(pc).to_numpy()
58     def x(b):
59         num=(b[cols].to_numpy()-mu)/sd
60         mat=np.array([[float(v==k) for k in pc] for v in b.protocol],dtype=float).reshape(len(b),len(pc))-freq
61         return np.c_[np.ones(len(b)),num,mat,b.source_aux.to_numpy()]
62     xc=x(c);xa=x(a);xe=x(e);y=c.score.to_numpy();ya=a.score.to_numpy()
63     if len(a):
64         counts=a.lineage.value_counts();w0=a.lineage.map(lambda g:len(c)/(len(counts)*counts[g])).to_numpy()
65         else:w0=np.zeros(0)
66     return { 'cxx':xc.T@xc,'cxy':xc.T@y,'axx':xa.T@(w0[:,None]*xa),'axy':xa.T@(w0*ya),'xe':xe,'cols':cols,'
    ↪     sd':sd,'mu':mu,'pc':pc,'freq':freq,'x':x,'xc':xc,'xa':xa,'yc':y,'ya':ya,'wa':w0 }
67 def solve(p,pa,pt,w):
68     penalty=np.array([0]+[pt if c=='time' else pa for c in p['cols']]+[100*pa]*len(p['pc'])+[100*pa])
69     linear=np.linalg.solve(p['cxx']+w*p['axx']+np.diag(penalty),p['cxy']+w*p['axy'])
70     mean=np.clip(p['yc'].mean()/100,1e-5,1-1e-5);scale=100*mean*(1-mean)

```

```

71 weights=np.r_[np.ones(len(p['yc'])),w*p['wa']];x=np.vstack([p['xc'],p['xa']]);y=np.r_[p['yc'],p['ya']];sqrt
    ↪ w=np.sqrt(weights)
72 reg=scale*np.sqrt(penalty)
73 def residual(co):return np.r_[sqrtw*(100*expit(x@co)-y),reg*co]
74 def jac(co):
75     prob=expit(x@co);return np.vstack([(sqrtw*100*prob*(1-prob))[:,None]*x,np.diag(reg)])
76 initial=linear/scale;initial[0]=np.log(mean/(1-mean))+(linear[0]-100*mean)/scale
77 fit=least_squares(residual,initial,jac=jac,max_nfev=300,ftol=1e-8,xtol=1e-8,gtol=1e-8)
78 if not fit.success:raise RuntimeError('bounded fit convergence failure')
79 return fit.x
80 def candidates(kind):return GRID if kind=='aux_dynamic' else [(a,b,0.) for a in [1.,10.,100.] for b in
    ↪ [10.,100.,1000.]] if kind=='core_dynamic' else [(a,0.,0.) for a in [1.,10.,100.]]
81 def select(c,a,kind,rolling=False):
82     temporal=kind!='core_scale';cache=[]
83     if rolling:
84         dates=np.sort(c.date.unique())
85         for i in range(1,len(dates)):
86             train=c[c.date<dates[i]];test=c[c.date==dates[i]]
87             if len(train)<8:continue
88             aa=a[(a.date<dates[i])&(a.submission<dates[i])]
89             cache.append((prepare(train,aa,test,temporal),test.score.to_numpy()))
90     if not cache:
91         for g in sorted(c.lineage.unique()):
92             train=c[c.lineage!=g];test=c[c.lineage==g];aa=a[a.lineage!=g]
93             if len(train)<4:continue
94             cache.append((prepare(train,aa,test,temporal),test.score.to_numpy()))
95     out=[]
96     for pa,pt,w in candidates(kind):
97         err=[np.mean(abs(100*expit(p['xe']@solve(p,pa,pt,w))-y)) for p,y in cache]
98         out.append((float(np.mean(err)),pa,pt,w))
99     return min(out,key=lambda z:(z[0],z[3],-z[2])),out,len(cache)
100 folds=[]
101 for design,col in [('lineage','lineage'),('publisher','publisher')]:
102     for g in sorted(core[col].unique()):
103         train=core[core[col]!=g];test=core[core[col]==g]
104         aa=aux[(aux[col]!=g)&~aux.lineage.isin(test.lineage.unique())]
105         folds.append((design,g,train,aa,test,False))
106 cut=core.date.sort_values().iloc[int(.75*len(core))];folds.append(('latest_cohort',str(cut.date()),core[core.
    ↪ date<cut],aux[(aux.date<cut)&(aux.submission<cut)],core[core.date>=cut],True))
107 # Several historical cutoffs: hold all models from each of last 3 years/month regimes, no invented
    ↪ 12-month validation.
108 for ct in [pd.Timestamp('2024-06-01'),pd.Timestamp('2024-09-01')]:
109     train=core[core.date<ct];test=core[core.date>=ct]
110     if len(train)>=8 and len(test):folds.append(('chronology_stress',str(ct.date()),train,aux[(aux.date<ct)&(au
    ↪ x.submission<ct)],test,True))
111 rows=[];params=[]
112 for design,held,c,a,e,rolling in folds:
113     for kind in ['aux_dynamic','core_dynamic','core_scale']:
114         (err,pa,pt,w),_nf=select(c,a,kind,rolling);prep=prepare(c,a,e,kind!='core_scale');coef=solve(prepare(pa,pt,
    ↪ w);pr=100*expit(prepare['xe']@coef)
115         params.append({'design':design,'held':held,'model':kind,'pa':pa,'pt':pt,'aux_weight':w,'core_train_n':len(c
    ↪ ),'aux_available_n':len(a),'aux_used_n':len(a) if w else 0,'inner_folds':nf,'inner_error':err})
116 for (_,r),v in zip(e.iterrows(),pr):rows.append({'design':design,'held':held,'model':kind,'name':r.model,'tr
    ↪ ack':r.track,'observed':r.score,'prediction':float(v),'constant':float(c.score.mean())})
117 print(design,held,flush=True)

```

```

118 pred=pd.DataFrame(rows);pred.to_csv(O/分组与时间留出预测.csv',index=False,encoding='utf-8-sig');
    ↪ pd.DataFrame(params).to_csv(O/训练折选参与辅助权重.csv',index=False,encoding='utf-8-sig')
119 metrics=[]
120 for (design,kind),g in pred.groupby(['design','model']):
121     err=abs(g.prediction-g.observed);metrics.append({'design':design,'model':kind,'n_predictions':len(g),'uni
    ↪ que_models':g.name.nunique(),'MAE':err.mean(),'group_balanced_MAE':g.assign(err=err).groupby
    ↪ ('held').err.mean().mean(),'constant_MAE':abs(g.constant-g.observed).mean(),'range_violations':int(
    ↪ ((g.prediction<0)|(g.prediction>100)).sum())})
122 pd.DataFrame(metrics).to_csv(O/模型对比.csv',index=False,encoding='utf-8-sig')
123 # Fixed reference population contrast; disclose composition/unexplained part.
124 best,search,_,_=select(core,aux,'aux_dynamic');_,pa,pt,w=best;prep=prepare(core,aux,core,True);coef=solv
    ↪ e(prep,pa,pt,w)
125 rawcoef={c:float(coef[i+1]/prep['sd'][i]) for i,c in enumerate(prep['cols'])};mid=(core.time.min()+core.ti
    ↪ me.max())/2;lo=core[core.time<=mid];hi=core[core.time>mid];dn=hi.logN.mean()-lo.logN.mean();
    ↪ dt=hi.time.mean()-lo.time.mean();observed=hi.score.mean()-lo.score.mean()
126 def attr(co):
127     def state(scale_values,t):
128         copies=[]
129         for val in scale_values:
130             dd=core.copy();dd['logN']=val;dd['time']=t;copies.append(dd)
131             xx=prep['x'](pd.concat(copies,ignore_index=True));return float(np.mean(100*expit(xx@co)))
132         v00=state(lo.logN,lo.time.mean());v10=state(hi.logN,lo.time.mean());v01=state(lo.logN,hi.time.mean());
    ↪ v11=state(hi.logN,hi.time.mean())
133         n=.5*((v10-v00)+(v11-v01));t=.5*((v01-v00)+(v11-v10));total=v11-v00
134         return {'scale_points':float(n),'time_points':float(t),'model_gain':float(total),'time_share':float(t/total) if
    ↪ abs(total)>.001 else
    ↪ None,'observed_gap':float(observed),'composition_residual':float(observed-total)}
135 att=attr(coef);sens=[]
136 for err,aa,bb,ww in
    ↪ search:sens.append({'inner_error':err,'pa':aa,'pt':bb,'aux_weight':ww,**attr(solve(prep,aa,bb,ww))})
137 pd.DataFrame(sens).to_csv(O/贡献规格敏感性.csv',index=False,encoding='utf-8-sig')
138 # Clock sensitivity core-only: auxiliary observations lack fixed-revision file dates.
139 clockmetrics=[]
140 for clock in ['first_format_ready','latest_format_update']:
141     a=core.merge(audit[['model',clock]],on='model',validate='one_to_one');a['date']=pd.to_datetime(a[clock]
    ↪ ,utc=True).dt.tz_localize(None).dt.normalize();a=a[a.date.notna()&a.date.le(a.submission)];a['time']
    ↪ =(a.date-pd.Timestamp('2020-01-01')).dt.days/365.25
142     ccut=a.date.sort_values().iloc[int(.75*len(a))]
143     for design in ['lineage','latest_cohort']:
144         ff=[(a[a.lineage!=g],a[a.lineage==g],False) for g in sorted(a.lineage.unique())] if design=='lineage' else
    ↪ [(a[a.date<ccut],a[a.date>=ccut],True)]
145         pp=[];yy=[];cc=[]
146         for c,e,rolling in ff:
147             (er,aa,bb,ww),_,_=select(c,aux.iloc[:0],['core_dynamic',rolling];pr=prepare(c,aux.iloc[:0],e);co=solve(pr
    ↪ ,aa,bb,0);pp+=list(100*expit(pr['xe']@co));yy+=list(e.score);cc +=[c.score.mean()]*len(e)
148         clockmetrics.append({'clock':clock,'design':design,'n':len(yy),'MAE':float(np.mean(abs(np.array(pp)-yy)
    ↪ )), 'constant_MAE':float(np.mean(abs(np.array(cc)-yy))), 't0':str(a.date.max().date()), 'plus12':str((a.d
    ↪ ate.max()+pd.DateOffset(months=12)).date()), 'plus24':str((a.date.max()+pd.DateOffset(months=24)
    ↪ ).date()), 'range_violations':int(((np.array(pp)<0)|(np.array(pp)>100)).sum())})
149 pd.DataFrame(clockmetrics).to_csv(O/版本时钟敏感性.csv',index=False,encoding='utf-8-sig')

```

```

150 summary={'status':'version_aligned_bounded_auxiliary_dynamics_executed','core_O_n':len(core),'auxili
    ↪ ary_W_not_O_n':len(aux),'core_tracks':core.track.value_counts().to_dict(),'aux_tracks':aux.track.val
    ↪ ue_counts().to_dict(),'core_publishers':core.publisher.nunique(),'core_lineage_proxies':core.lineage.
    ↪ nunique(),'aux_lineage_proxies':aux.lineage.nunique(),'primary_clock':'fixed-revision earliest listed
    ↪ weight-format timestamp; both core and
    ↪ auxiliaries','primary_window':[str(core.date.min().date()),str(core.date.max().date())],'primary_event
    ↪ _targets':[str((core.date.max()+pd.DateOffset(months=h)).date()) for h in
    ↪ [12,24]],'common_snapshot_forecast_anchor':'2025-03-13','snapshot_targets':['2026-03-13','2027-03
    ↪ -13'],'last_cohort_cutoff':str(cut.date()),'metrics':metrics,'clock_sensitivity':clockmetrics,'full_fit_pen
    ↪ alties':{'scale':pa,'time':pt,'aux_weight':w},'coefficients_on_latent_logit_scale':rawcoef,'attribution':a
    ↪ tt,'time_share_grid_range':[min(v['time_share'] for v in sens if v['time_share'] is not
    ↪ None),max(v['time_share'] for v in sens if v['time_share'] is not
    ↪ None)],'final_choice_frozen':False,'new_long_horizon_forecast':False,'industry_causal_share':None,'
    ↪ inputs':{'str(p.relative_to(R)):hashlib.sha256(p.read_bytes()).hexdigest() for p in
    ↪ [S,J,V,VA]},'C2_sha256':hashlib.sha256(raw).hexdigest(),'script_sha256':hashlib.sha256(Path(__fil
    ↪ e__).read_bytes()).hexdigest()}
151 (O/'summary.json').write_text(json.dumps(summary,ensure_ascii=False,indent=2,default=lambda v:int(v)
    ↪ if isinstance(v,np.integer) else
    ↪ v));print(json.dumps(summary,ensure_ascii=False,indent=2,default=lambda v:int(v) if
    ↪ isinstance(v,np.integer) else v))

```